

CHƯƠNG 14: DỰ BÁO THỜI TIẾT NGẮN HẠN CHO NÔNG NGHIỆP CHÍNH XÁC Ở JAMMU VÀ KASHMIR: PHƯƠNG PHÁP TIẾP CẬN HỌC SÂU

Syed Nisar Hussain Bukhari và Sana Farooq Pandit Viện Công nghệ Thông tin và Điện tử Quốc gia (NIELIT), Srinagar, Ấn Độ

14.1 GIỚI THIỆU

Sản xuất nông nghiệp đóng vai trò là nguồn phát triển kinh tế chính ở bất kỳ quốc gia nào, và dự báo thời tiết (WF) ảnh hưởng trực tiếp hoặc gián tiếp đến lợi nhuận hoặc thua lỗ hàng năm của sản xuất nông nghiệp. WF cho phép nông dân dự đoán và ngăn ngừa các thiệt hại tiềm ẩn gây ra bởi các hiện tượng thời tiết khắc nghiệt, bao gồm giảm năng suất, tưới tiêu sai, lựa chọn cây trồng không phù hợp và thời điểm thu hoạch không chính xác. Những thay đổi thời tiết không thể đoán trước có thể cản trở đáng kể tiến bộ nông nghiệp trong một thời gian dài. Khả năng dự đoán tuyết rơi, mưa, sóng nhiệt và lũ lụt sắp xảy ra giúp nông dân lập chiến lược và giảm thiểu các tác động tàn phá của các sự kiện đó.

Với sự tiến bộ của trí tuệ nhân tạo (AI) trong WF, độ tin cậy và độ chính xác của các dự đoán đã được cải thiện đáng kể. Các thuật toán AI dựa trên dữ liệu như mạng nơ-ron (NN) có thể được sử dụng để phân tích dữ liệu thời tiết lịch sử và dự báo các xu hướng cũng như các kiểu mẫu thời tiết trong tương lai. Các mô hình này cũng cải thiện độ chính xác của các dự đoán thời tiết ngắn hạn, giúp các nhà nông nghiệp đưa ra các quyết định sáng suốt. Ngược lại, hiệu suất của các kỹ thuật thống kê như Trung bình Trượt Tự hồi quy (ARMA) và các biến thể của nó phụ thuộc vào cả chất lượng dữ liệu và khả năng biểu diễn chính xác dữ liệu chuỗi thời gian (TS) thể hiện các mẫu không dừng (non-stationary) qua các mùa khác nhau.

Các hệ thống lập mô hình dựa trên dữ liệu có thể được sử dụng để giảm yêu cầu tính toán của Dự báo Thời tiết Số trị (NWP) đồng thời tính đến sự không chắc chắn có trong các quan sát và nhiễu hệ thống. Điều này có thể là do khả năng của các mô hình dựa trên dữ liệu trong việc ước tính các mẫu và động lực nội tại của dữ liệu TS, ngay cả khi không có kiến thức trước về các tham số.

Cụ thể, Mạng Nơ-ron Nhân tạo (ANN) có thể được sử dụng cho mục tiêu này nhờ vào các đặc tính thích ứng và khả năng học hỏi từ kiến thức trước đó. Những đặc điểm này làm cho ANN trở nên hấp dẫn trong các lĩnh vực đa dạng, đặc biệt là khi xử lý các hiện tượng phi tuyến phức tạp có trong các bộ dữ liệu như bộ dữ liệu thời tiết. Các loại NN khác nhau, chẳng hạn như NN truyền thẳng (feedforward NN), NN sử dụng lan truyền ngược (back propagation), Mạng Nơ-ron Hồi quy (RNN), và Bộ nhớ Dài-Ngắn hạn (LSTM), áp dụng một cách tiếp cận dự đoán riêng biệt, mỗi loại cung cấp một phương pháp độc đáo để đạt được kết quả chính xác.

Để xử lý hiệu quả dữ liệu thời tiết, các mô hình RNN và LSTM được coi là những lựa chọn vượt trội do khả năng xử lý hiệu quả dữ liệu TS. Các NN thông thường thiếu sức mạnh cần thiết để nắm bắt các phụ thuộc dài hạn. Khi số lượng lớp tăng lên, chúng dễ gặp phải vấn đề tiêu biến gradient (vanishing gradient). Mặt khác, Mạng Nơ-ron Hồi quy (RNN) rất phù hợp để xử lý dữ liệu TS với các thang thời gian đa dạng, cho phép chúng lưu trữ thông tin dài hạn.

Để huấn luyện RNN, một bộ dữ liệu TS bao gồm các bản ghi hàng ngày về nhiệt độ tối thiểu (min temp), nhiệt độ tối đa (max temp) và giá trị lượng mưa đã được thu thập từ Cục Khí tượng Ấn Độ (IMD). Nghiên cứu này nhằm mục đích thiết lập một khung mô hình dự đoán cho WF ngắn hạn nhằm hỗ trợ nông dân quản lý tài nguyên nông nghiệp hiệu quả và lập kế hoạch cho các hoạt động canh tác của họ trước thời hạn. Mô hình sẽ sử dụng các giá trị trong quá khứ trong một bước thời gian xác định làm đầu vào để dự báo các giá trị nhiệt độ tối thiểu, nhiệt độ tối đa và lượng mưa trong số ngày ngắn hơn.

14.1.1 Đóng góp

Những đóng góp chính của nghiên cứu này được tóm tắt như sau:

- Giảm gánh nặng kinh tế trực tiếp và gián tiếp gây ra do sự phụ thuộc của nông dân vào các dự đoán thời tiết sai lầm.
- Chủ động giảm thiểu các thiệt hại tiềm ẩn trong ngành nông nghiệp do các tình huống thời tiết khắc nghiệt gây ra.
- Xây dựng một mô hình học sâu (DL) được thiết kế đặc biệt cho WF ngắn hạn sử dụng dữ liệu TS.
- Tạo ra các dự đoán thời tiết chính xác trong một khung thời gian giới hạn bằng cách sử dụng dữ liệu thời tiết địa phương hóa.
- Xây dựng một mô hình WF thể hiện khả năng thích ứng mạnh mẽ với các xu hướng đang thay đổi trong dữ liệu thời tiết và xử lý hiệu quả các sự kiện thời tiết khắc nghiệt trong khi vẫn duy trì hiệu suất nhất quán.

14.2 CÁC CÔNG TRÌNH LIÊN QUAN

Nhiều kỹ thuật khác nhau dựa trên cả phương pháp thống kê và mô hình dựa trên dữ liệu đã được thiết kế theo thời gian để dự báo các điều kiện thời tiết bằng cách dự đoán một hoặc nhiều tham số liên quan đến thời tiết. Các nhà nghiên cứu [6] đã tiến hành một nghiên cứu để dự đoán cường độ mưa bằng cách sử dụng nhiệt độ hàng ngày, độ ẩm, hướng gió, tốc độ gió và tốc độ mây. Các mô hình dự đoán được xây dựng bằng Cây Quyết định (DT), Hồi quy Vector Hỗ trợ (SVR), và Rừng Ngẫu nhiên (RF), đạt được điểm R^2 lần lượt là 0.806, 0.900, và 0.980.

Trong một nghiên cứu khác, các nhà nghiên cứu [7] đã huấn luyện các mô hình học máy khác nhau để dự đoán lượng mưa nhằm hỗ trợ nông nghiệp chính xác ở Sri Lanka. Các mô hình được huấn luyện bằng cách sử dụng các thuộc tính như máy đo mưa, độ ẩm

tương đối, nhiệt độ trung bình, tốc độ gió, hướng gió, bức xạ mặt trời và nồng độ ozone đặc trưng cho khu vực Sri Lanka. Người ta quan sát thấy rằng RF hoạt động tốt nhất với độ chính xác 89.16%.

Trong công trình của mình, các nhà nghiên cứu [8] đã kết hợp các kỹ thuật học máy với các kỹ thuật khai thác dữ liệu để phát triển một mô hình dự đoán lượng mưa, và người ta quan sát thấy rằng các mô hình Trung bình Trượt Tích hợp Tự hồi quy (ARIMA) và NN cung cấp độ chính xác tốt nhất là 70.5%.

Trong thập kỷ qua, RNN đã thu hút sự chú ý đáng kể và chứng kiến sự tiến bộ đáng kể vì khả năng lập mô hình mạnh mẽ và có ảnh hưởng của chúng. Trong một nghiên cứu, các nhà nghiên cứu [10] đã sử dụng lưu lượng và lượng mưa hàng ngày để dự báo lũ lụt. Các kết quả nghiên cứu cho thấy tiềm năng sử dụng LSTM, một biến thể của RNN, để phát triển và quản lý các hệ thống cảnh báo lũ lụt thời gian thực.

Trong nghiên cứu thực nghiệm của mình, các nhà nghiên cứu [1] đã kết luận rằng mô hình LSTM vượt trội hơn mô hình ARIMA trong việc dự đoán nhiệt độ tối thiểu và tối đa với điểm lỗi bình phương trung bình gốc (RMSE) là 1.04. Nghiên cứu được thực hiện bởi Gumaste và Kadam [11] đã sử dụng Thuật toán Di truyền (GA) và Biến đổi Fourier Nhanh (FFT) để dự đoán thời tiết trong tương lai bằng cách sử dụng dữ liệu hiện tại. Các mô hình sau đó đã được triển khai thông qua các ứng dụng di động để hỗ trợ nông dân lập kế hoạch cho các công việc trước và sau nông nghiệp của họ.

Để đạt được các dự báo thời tiết chính xác cho làng Dellangu của Indonesia, các nhà nghiên cứu đã phát triển một mô hình dự đoán thời tiết ngắn hạn sử dụng ANN để giúp nông dân giải quyết các vấn đề đồng lúa của họ. Một nghiên cứu khác đã tiến hành phân tích so sánh giữa mười mô hình hồi quy học máy cơ sở và một mô hình tập hợp (ensemble model). Phân tích cho thấy mô hình tập hợp hoạt động tốt hơn các mô hình cơ sở trong việc dự đoán lượng mưa, độ ẩm tương đối, nhiệt độ tối đa và tối thiểu.

Để giảm chi phí thiệt hại nông nghiệp do sương giá, các nhà nghiên cứu đã huấn luyện các mô hình học máy như mạng nơ-ron tích chập, mạng nơ-ron sâu, và RF để dự đoán các sự kiện sương giá. Nghiên cứu đã xác định rằng nhiệt độ đất là một yếu tố quan trọng khi đưa ra dự đoán ngoài 24 giờ, trong khi đối với các dự báo ngắn hạn hơn, hầu hết các thông tin liên quan được lấy từ các tham số liên quan đến nhiệt độ khác.

14.3 CÔNG TRÌNH ĐỀ XUẤT


Nghiên cứu này trình bày một mô hình WF sáng tạo và gọn nhẹ (lightweight) được thiết kế đặc biệt để dự đoán ngắn hạn chính xác về nhiệt độ và lượng mưa ở Jammu và Kashmir (J&K). Mô hình được thiết kế để tương thích với các máy tính cá nhân độc lập và có thể dễ dàng triển khai trong khu vực địa lý J&K. Hệ thống đề xuất sử dụng một kỹ thuật DL tiên tiến được gọi là RNN, phù hợp với dữ liệu tuần tự và có thể nâng cao độ

chính xác của các dự đoán. Phần dưới đây cung cấp một giải thích chi tiết về mô hình RNN.

14.3.1 Mạng Nơ-ron Hồi quy

Một RNN truyền thống [15] có thể được coi là một biến thể của NN truyền thẳng sở hữu một thành phần bộ nhớ trong để xử lý các chuỗi đầu vào. RNN có khả năng học các phụ thuộc từ các thuật ngữ trước đó và dự đoán các thước đo tích lũy từ các chuỗi có độ dài thay đổi, bao gồm cả thành phần thời gian. RNN đặc biệt hữu ích để phát triển các mô hình dự đoán bằng cách sử dụng các bộ dữ liệu TS dài hạn, điều này có thể hữu ích trong WF.

Không giống như các NN sâu truyền thống giả định đầu vào và đầu ra không liên quan đến nhau, RNN tạo ra các đầu ra bị ảnh hưởng bởi các yếu tố trước đó trong chuỗi. Đối với điều đó, RNN sử dụng các vòng lặp phản hồi để tận dụng đầu ra từ một bước thời gian làm đầu vào cho bước tiếp theo. Bằng cách duy trì thông tin một cách tuần tự, đầu vào của RNN tại mỗi bước thời gian kết hợp cả dữ liệu từ bước thời gian hiện tại trong chuỗi và thông tin trước đó được truyền qua vòng lặp phản hồi. Bản chất hồi quy của RNN xuất phát từ việc áp dụng nhất quán cùng một hàm để tính toán đầu ra cho mỗi đầu vào, với đầu ra bị ảnh hưởng bởi các tính toán trước đó.



HÌNH 14.1 Hoạt động của RNN.

Hình 14.1 minh họa một kiến trúc RNN cơ bản trong đó x_t đến x_{t+1} đại diện cho các đầu vào cho mỗi chuỗi, và y_t đến y_{t+1} đại diện cho các đầu ra tương ứng được tạo ra cho mỗi chuỗi. Rõ ràng là tất cả các đầu vào được kết nối với nhau, với mỗi kết nối được ký hiệu bằng một ô RNN duy nhất. Các thuật ngữ f_{t-1} đến f_{t+1} đề cập đến các trạng thái ẩn, và θ đại diện cho trọng số của các trạng thái ẩn; α biểu thị trọng số của trạng thái đầu vào hiện tại; β đại diện cho trọng số tại trạng thái đầu ra.

Trái ngược với các NN truyền thẳng truyền thống nơi các trọng số là riêng biệt cho mỗi nút, RNN sử dụng các tham số được chia sẻ qua các lớp, ngụ ý rằng trong mỗi lớp của RNN, cùng một tham số trọng số được áp dụng. Tuy nhiên, các trọng số được chia sẻ này

vẫn được cập nhật trong quá trình lan truyền ngược và giảm gradient để cho phép học tăng cường hiệu quả.

Hoạt động của RNN có thể được giải thích qua các bước sau:

Đối với một chuỗi các điểm dữ liệu x , được ký hiệu là $x = [x_{t-1}, x_t, x_{t+1} \dots]$ trong đó x_t đại diện cho đầu vào tại một bước thời gian “ t ” cụ thể trong chuỗi:

- Trạng thái ẩn tại bước thời gian “ t ”, ký hiệu là f_t được tính toán bằng cách kết hợp đầu vào hiện tại x_t với trạng thái ẩn trước đó f_{t-1} . Phép tính này được biểu thị là: $f_t = \sigma(\alpha x_t + \theta f_{t-1})$, trong đó σ đại diện cho hàm kích hoạt được áp dụng cho tổng của các đầu vào có trọng số; α đại diện cho ma trận trọng số cho các kết nối từ đầu vào đến trạng thái ẩn; θ đại diện cho ma trận trọng số cho các kết nối trong trạng thái ẩn.
- Đầu ra y_t tại bước thời gian “ t ” có thể được tính toán bằng cách sử dụng trạng thái ẩn: $y_t = \sigma(\beta f_t)$ trong đó β là ma trận trọng số cho các kết nối từ ẩn đến đầu ra.

Hàm kích hoạt là một phép toán học được sử dụng để kết hợp tính phi tuyến vào NN, cho phép chúng học hiệu quả các mẫu dữ liệu phức tạp và thực hiện các thay đổi phi tuyến đối với dữ liệu đầu vào. Trong RNN, hàm kích hoạt chỉ được áp dụng cho các lớp ẩn vì lớp đầu vào chỉ chứa dữ liệu đầu vào và không trải qua bất kỳ phép tính nào.

Ngoài ra, đầu ra của RNN, đại diện cho dự đoán của mạng hoặc đầu ra được tạo ra tại mỗi bước thời gian, cũng có thể trải qua một hàm kích hoạt để chuyển đổi đầu ra thô thành một phạm vi hoặc định dạng ưu tiên dựa trên nhiệm vụ hoặc vấn đề cụ thể đang được giải quyết. Nếu không có sự hiện diện của các hàm kích hoạt phi tuyến, một mạng nơ-ron có nhiều lớp ẩn về cơ bản sẽ giống như một mô hình hồi quy tuyến tính quy mô lớn và sẽ không thể học hiệu quả các mẫu phức tạp và phức tạp từ dữ liệu thế giới thực. Các hàm kích hoạt thường được sử dụng là Rectified Linear Unit (ReLU), tanh, Sigmoid, và Softmax.

14.3.1.1 Lan truyền ngược Theo Thời gian (BPTT)

BPTT [16] là một phương pháp huấn luyện lặp đi lặp lại được sử dụng đặc biệt cho RNN. Nó mở rộng thuật toán lan truyền ngược tiêu chuẩn, thường được sử dụng để huấn luyện NN truyền thẳng, và kết hợp khía cạnh thời gian của RNN bằng cách cho phép các gradient lan truyền ngược theo thời gian, xem xét bản chất tuần tự của dữ liệu TS.


Trong RNN, trạng thái ẩn của mạng tại mỗi bước thời gian bị ảnh hưởng bởi cả đầu vào hiện tại và đầu ra từ trạng thái ẩn trước đó. Điều này làm phát sinh một chuỗi các phụ thuộc kéo dài ngược thời gian, cho phép BPTT mở rộng RNN theo thời gian. Một phân tích đơn giản về các bước liên quan đến BPTT được đưa ra tiếp theo:

Đối với một chuỗi các điểm dữ liệu x , được ký hiệu là $x = [x_{t-1}, x_t, x_{t+1} \dots]$, trong đó x_t đại diện cho đầu vào tại một bước thời gian “ t ” cụ thể trong chuỗi.

- Trạng thái ẩn tại bước thời gian “t”, ký hiệu là f_t , được tính toán bằng cách kết hợp đầu vào hiện tại x_t với trạng thái ẩn trước đó f_{t-1} . Phép tính này được biểu thị là: $f_t = \sigma(\alpha x_t + \theta f_{t-1})$, Trong đó σ , α , và θ có ý nghĩa như thường lệ.
- Hàm mất mát, chẳng hạn như lỗi bình phương trung bình (MSE) hoặc mất mát cross-entropy, được áp dụng để tính toán mất mát tại mỗi bước thời gian. Chúng ta có thể biểu thị mất mát tại một bước thời gian “t” cụ thể là l_t .
- Các gradient của mất mát đối với các tham số của mạng được tính toán từ bước thời gian cuối cùng. Sau đó, các gradient này được lan truyền theo hướng ngược lại qua các bước thời gian trước đó. Gradient tại bước thời gian “t”, biểu thị tác động của mất mát lên trạng thái ẩn tại “t” có thể được biểu thị là: $\frac{\partial l_t}{\partial f_t}$
- Các gradient được tích lũy tại mỗi bước khi chúng lan truyền theo thời gian, đảm bảo rằng các phụ thuộc giữa các bước thời gian khác nhau được nắm bắt một cách hiệu quả. Các gradient tích lũy được biểu thị như sau: $\frac{\partial l}{\partial f_t}$
- Các tham số của mạng được cập nhật bằng cách sử dụng các thuật toán tối ưu hóa như Adam, SGD và RMSprop. Cập nhật tham số cho mỗi trọng số có thể được tính là: $\Delta w = -\eta * \Sigma \frac{\partial l}{\partial w}$, trong đó Δw là cập nhật trọng số, và η là tốc độ học.

14.4 CÁC THÍ NGHIỆM

Hình 14.2 minh họa chi tiết quy trình lập mô hình toàn diện. Thí nghiệm bắt đầu với giai đoạn thu thập dữ liệu và tiền xử lý dữ liệu, được trình bày chi tiết trong phần tiếp theo. Sau đó, quy trình bao gồm cấu hình, huấn luyện, so sánh và đánh giá mô hình. Bước cuối cùng của thí nghiệm bao gồm việc đánh giá và đối chiếu hiệu suất của các mô hình đã được huấn luyện.



HÌNH 14.2 Minh họa về lập mô hình.

14.4.1 Thu thập Dữ liệu

Nghiên cứu này sử dụng dữ liệu khí tượng thực tế thu được từ trang web của IMD [17], cụ thể là từ các trạm thời tiết ở Jammu, Srinagar, và Leh. Bộ dữ liệu cho mỗi trạm thời tiết bao gồm một TS hàng ngày bao gồm 8.401 điểm dữ liệu, kéo dài từ ngày 1 tháng 1 năm 2010 đến ngày 31 tháng 12 năm 2022. Bộ dữ liệu bao gồm các biến thời tiết khác nhau, bao gồm lượng mưa, nhiệt độ tối thiểu và nhiệt độ tối đa. Giá trị lượng mưa được đo bằng milimét (mm), trong khi các biến nhiệt độ được ghi bằng độ C.

Các đặc trưng khí tượng cụ thể này được chọn vì chúng cung cấp những hiểu biết có giá trị về điều kiện thời tiết hiện tại tại một địa điểm và thời gian cụ thể. Việc lựa chọn các đặc trưng này nhằm mục đích nắm bắt chính xác trạng thái của thời tiết. Trong nghiên cứu này, ba đặc trưng khí tượng này được sử dụng làm biến đầu vào để dự đoán nhiệt độ.

14.4.2 Tiền xử lý Dữ liệu

Thí nghiệm được tiến hành trên dữ liệu thực tế đòi hỏi một số bước tiền xử lý để phản ánh chính xác hiệu suất của mô hình. Ban đầu, việc làm mịn dữ liệu đã được thực hiện để giảm nhiễu và biến động, đồng thời làm cho các mẫu và xu hướng cơ bản trở nên rõ ràng hơn. Dữ liệu đã được làm mịn bằng kỹ thuật Trung bình Trượt Lũy thừa (EMA).

EMA [18] là giá trị trung bình có trọng số trong đó các trọng số được giảm dần sao cho tầm quan trọng được trao nhiều hơn cho các điểm dữ liệu gần đây so với các điểm dữ liệu lịch sử, hoặc ngược lại. EMA thay đổi với tốc độ nhanh hơn và nhạy cảm hơn với các điểm dữ liệu. Về mặt toán học, EMA của một điểm dữ liệu có thể được tính bằng Phương trình 14.1:

$$\begin{aligned} EMA_t &= x_0 \text{ tại } t = 0 \\ \alpha x_t + (1 - \alpha)EMA_{t-1} \end{aligned} \quad (14.1)$$

trong đó α là một yếu tố làm mịn, và giá trị của nó nằm trong khoảng từ 0 đến 1. Nó đại diện cho trọng số được áp dụng cho giai đoạn rất gần đây. Đối với nghiên cứu này, giá trị của α đã được giữ ở mức 0.5.

Để làm cho TS dừng (stationary), phép sai phân (differencing) bậc một đã được thực hiện trên bộ dữ liệu thời tiết. Phép sai phân đòi hỏi tính toán sự khác biệt giữa các quan sát liên tiếp bằng cách trừ giá trị trước đó khỏi giá trị hiện tại. Mục đích của phép sai phân là để loại bỏ xu hướng cơ bản và cô lập các thay đổi hoặc biến động cụ thể có trong dữ liệu.

Đối với giai đoạn cuối cùng của tiền xử lý, dữ liệu đã được chuẩn hóa bằng kỹ thuật co giãn MinMax (MinMax scaling) vì các giá trị của các biến khác nhau trong bộ dữ liệu có các đơn vị khác nhau và nằm trong nhiều phạm vi. Về mặt toán học, co giãn MinMax được biểu thị bằng Phương trình 14.2:

$$X_t = \frac{X_t - X_{min}}{X_{max} - X_{min}}, \quad (14.2)$$

trong đó X_t đại diện cho điểm dữ liệu tại thời điểm “t” trong TS và X_{max} và X_{min} lần lượt đại diện cho các điểm dữ liệu tối đa và tối thiểu trong chuỗi.

Dữ liệu được chuẩn hóa cho phép các mô hình tổng quát hóa tốt trên dữ liệu mới và chưa từng thấy. Ngoài ra, các hàm kích hoạt trong các nơ-ron RNN và LSTM hoạt động hiệu quả hơn trên dữ liệu được chuẩn hóa. Bộ dữ liệu đã được chia thành một tập huấn luyện và một tập kiểm tra, với tỷ lệ lần lượt là 0.8 và 0.2. Tập dữ liệu huấn luyện của mỗi trạm thời tiết bao gồm 6.720 hàng chứa dữ liệu thời tiết từ ngày 1 tháng 1 năm 2000 đến ngày 25 tháng 5 năm 2018, trong khi tập dữ liệu kiểm tra chứa 1.680 hàng kéo dài từ ngày 26 tháng 5 năm 2018 đến ngày 31 tháng 12 năm 2022. Các chuỗi đầu vào và đầu ra đã được thu thập bằng thuật toán cửa sổ trượt (moving window) và kích thước cửa sổ là bảy. Cả chuỗi đầu vào và đầu ra đều chứa ba đặc trưng.

14.4.3 Cấu hình và Huấn luyện Mô hình

Các mô hình đề xuất đã được huấn luyện bằng hai cấu hình riêng biệt: Đầu vào Đơn Đầu ra Đơn (SISO) và Đầu vào Nhiều Đầu ra Nhiều (MIMO). SISO là một sắp xếp dự báo trong đó một biến đầu vào duy nhất được đưa vào mạng để dự báo các giá trị tương lai của cùng một biến đó làm đầu ra. Mặt khác, trong MIMO, nhiều biến được đưa vào mạng để dự đoán các biến tương tự làm đầu ra.

Sử dụng cấu hình này, chỉ cần một mô hình cho mỗi trạm thời tiết để dự đoán tất cả các giá trị trong tương lai, trong khi ở SISO, cần ba mô hình khác nhau cho mỗi trạm thời tiết để dự báo ba tham số thời tiết. Do đó, ba mô hình RNN đã được huấn luyện và đánh giá bằng cách sử dụng cấu hình MIMO cho ba trạm thời tiết riêng biệt. Ngoài ra, tổng cộng chín mô hình RNN đã được cả huấn luyện và kiểm tra trong cấu hình SISO để dự báo ba biến nhiệt độ trên ba trạm thời tiết.

Cả hai cấu hình đã được huấn luyện trên các bộ siêu tham số khác nhau của RNN. Siêu tham số (Hyperparameters) là các giá trị cụ thể phải được xác định trước khi huấn luyện mô hình và không phải học hoặc điều chỉnh trong quá trình huấn luyện mô hình. Các siêu tham số được tinh chỉnh trong nghiên cứu này bao gồm số lượng epoch, kích thước lô (batch size), thuật toán tối ưu hóa, và các hàm kích hoạt.

Kỹ thuật được chọn để tinh chỉnh siêu tham số là GridSearchCV, tự động hóa quá trình thử các cấu hình siêu tham số khác nhau. Nó khám phá kỹ lưỡng một lưới các giá trị siêu tham số được xác định trước để xác định sự kết hợp tạo ra hiệu suất mô hình cao nhất.

Đối với mô hình RNN, số lượng epoch xác định số lần mô hình sẽ được huấn luyện trên toàn bộ dữ liệu. Trong mỗi epoch, mô hình trải qua một lượt truyền xuôi (từ đầu vào đến đầu ra) và một lượt truyền ngược (điều chỉnh trọng số dựa trên gradient) cho tất cả các mẫu huấn luyện. Sử dụng số lượng epoch nhỏ hơn dẫn đến tăng mất mát lỗi, trong khi số lượng epoch lớn hơn có thể gây ra hiện tượng quá khớp (overfitting). Các mô hình đã được huấn luyện trong khoảng 50-300 epoch.

Kích thước lô đề cập đến số lượng mẫu huấn luyện được mô hình xử lý cùng nhau trong một lượt truyền xuôi và ngược, cho phép mô hình cập nhật trọng số sau khi xử lý một nhóm mẫu. Sử dụng kích thước lô lớn hơn trong quá trình huấn luyện mô hình đi kèm với chi phí tính toán cao hơn, trong khi kích thước lô nhỏ hơn gây ra nhiễu trong mô hình. Do đó, các thí nghiệm huấn luyện đã được tiến hành với các kích thước lô là 16, 32, 64, và 128 để tìm ra cấu hình tối ưu.

Việc lựa chọn thuật toán tối ưu hóa ảnh hưởng đến cả tốc độ mô hình đạt được giải pháp tối ưu và khả năng tổng quát hóa hiệu quả đối với dữ liệu chưa từng thấy. Để xác định thuật toán tối ưu hóa phù hợp nhất, các mô hình đã trải qua quá trình huấn luyện bằng cách sử dụng các trình tối ưu hóa Adam, SGD, và RMSprop. Để lựa chọn hàm kích hoạt tối ưu, các mô hình đã được huấn luyện trên các hàm kích hoạt tanh, ReLU, và sigmoid.

14.4.4 Đánh giá Mô hình

Các mô hình đã được huấn luyện lặp đi lặp lại trên dữ liệu huấn luyện và được đánh giá trên dữ liệu kiểm tra. Để đánh giá các mô hình hồi quy TS, các số liệu thường được sử dụng là lỗi tuyệt đối trung bình (MAE), MSE, RMSE, và lỗi phần trăm tuyệt đối trung bình (MAPE), được tính bằng các Phương trình 14.3-14.6:

$$MAE = \sum_{t=1}^N |y_t - \hat{y}_t| \quad (14.3)$$

$$MSE = \sum_{t=1}^N (y_t - \hat{y}_t)^2 \quad (14.4)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{t=1}^N (y_t - \hat{y}_t)^2} \quad (14.5)$$

$$MAPE = \frac{100}{N} \sum_{t=1}^N \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad (14.6)$$

trong đó y_t và $\hat{y}_t$ là các giá trị thực tế và dự đoán của các biến nhiệt độ tại bước thời gian “t”.

14.5 KẾT QUẢ VÀ THẢO LUẬN

Như đã đề cập trong Mục 14.3, mô hình RNN đã được huấn luyện bằng cách sử dụng các bộ siêu tham số khác nhau và được kiểm tra bằng các số liệu đánh giá khác nhau. Đối với mỗi trạm, người ta đã quan sát thấy rằng mô hình RNN hoạt động tốt hơn đáng kể trong cấu hình SISO so với cấu hình MIMO. Các giá trị của các số liệu độ chính xác khác nhau cho các mô hình RNN được liệt kê trong Bảng 14.1 cho tất cả các trạm thời tiết. Bảng 14.2-14.4 liệt kê các số liệu độ chính xác của mô hình RNN trong cấu hình SISO cho Jammu, Srinagar, và Leh.

Những phát hiện này chỉ ra rằng các biến có trong dữ liệu thời tiết là tương đối đơn biến (univariate) và không có các phụ thuộc lẫn nhau mạnh mẽ giữa chúng. Các mối quan hệ như vậy có thể được biểu diễn đầy đủ bằng cách sử dụng một biến đầu vào duy nhất để dự báo một biến đầu ra duy nhất.

BẢNG 14.1: Hiệu suất Mô hình trong Cấu hình MIMO cho tất cả các Trạm

Số liệu	Giá trị Tương ứng cho Trạm Jammu	Giá trị Tương ứng cho Trạm Srinagar	Giá trị Tương ứng cho Trạm Leh
MAE	0.0636	0.1048	0.8543
MSE	0.0401	0.0455	0.0411
RMSE	0.1011	0.1555	0.1344
MAPE	0.3990	0.4398	0.3229
[cite: 1208]			

BẢNG 14.2: Hiệu suất Mô hình trong Cấu hình SISO cho Trạm Jammu

Biến Nhiệt độ	T_{min}	T_{max}	Lượng mưa
MAE	0.0751	0.0690	0.0124
MSE	0.0095	0.0095	0.0257
RMSE	0.0977	0.0091	0.0006

Biến Nhiệt độ	T_{min}	T_{max}	Lượng mưa
MAPE	0.1863	0.1683	0.1229

BẢNG 14.3: Hiệu suất Mô hình trong Cấu hình SISO cho Trạm Srinagar

Biến Nhiệt độ	T_{min}	T_{max}	Lượng mưa
MAE	0.0658	0.0696	0.0210
MSE	0.0073	0.0926	0.0018
RMSE	0.0854	0.0085	0.0429
MAPE	0.1436	0.1696	0.1368

BẢNG 14.4: Hiệu suất Mô hình trong Cấu hình SISO cho Trạm Leh

Biến Nhiệt độ	T_{min}	T_{max}	Lượng mưa
MAE	0.0666	0.0085	0.0640
MSE	0.0075	0.0015	0.0078
RMSE	0.0866	0.0393	0.0887
MAPE	0.1547	0.0588	0.1623

14.6 KẾT LUẬN VÀ PHẠM VI TƯƠNG LAI

Nghiên cứu này nhấn mạnh tầm quan trọng của việc lựa chọn dữ liệu khu vực trong việc xây dựng một mô hình WF đáng tin cậy và giải quyết vấn đề WF bằng cách tập trung vào việc đạt được các dự báo chính xác mà không yêu cầu tài nguyên tính toán đáng kể, trái ngược với các phương pháp NWP. Để giải quyết vấn đề này, một mô hình dự đoán dựa trên DL gọn nhẹ đã được đề xuất để đảm bảo WF ngắn hạn chính xác. Mô hình được đề xuất có khả năng hoạt động độc lập trên một đơn vị máy tính duy nhất và có thể dễ dàng triển khai trong khu vực địa lý của J&K.

Trong tương lai, nhiều biến hơn như tốc độ gió, độ ẩm, và áp suất có thể được tích hợp vào quá trình huấn luyện mô hình để cung cấp một dự báo thời tiết đa dạng hơn. Các kết quả cũng cho thấy SISO hoạt động tốt hơn các cấu hình MIMO ; tuy nhiên, điều đó sẽ đòi hỏi ba mô hình khác nhau để dự đoán ba tham số thời tiết làm đầu ra. Trong các thí nghiệm tương lai, các cấu hình MIMO có thể được tối ưu hóa hơn nữa để tăng cường cả hiệu suất và hiệu quả đồng thời.

TÀI LIỆU THAM KHẢO

- [1] Z. Prathyusha, T. Savya, N. Alex, and C. Sobin, "A Method for Weather Forecasting Using Machine Learning," in *2021 5th Conference on Information and Communication Technology, CICT 2021*, Institute of Electrical and Electronics Engineers Inc., 2021. doi: 10.1109/CICT53865.2020.9672403

- [2] S. Poornima, and M. Pushpalatha, "Prediction of Rainfall Using Intensified LSTM Based Recurrent Neural Network with Weighted Linear Units," *Atmosphere (Basel)*, vol. 10, no. 11, Nov. 2019. doi: 10.3390/atmos10110668
- [3] M. Hayati, and Z. Mohebi, "Application of Artificial Neural Networks for Temperature Forecasting", *International Science Index, Electrical and Computer Engineering*, vol. 1, no. 4, pp. 662–666, 2007.
- [4] F. Kratzert, D. Klotz, C. Brenner, K. Schulz, and M. Herrnegger, "Rainfall-Runoff Modelling Using Long Short-Term Memory (LSTM) Networks," *Hydrology and Earth System Sciences*, vol. 22, no. 11, pp. 6005–6022, Nov. 2018. doi: 10.5194/hess-22-6005-2018
- [5] T. Kashiwao, K. Nakayama, S. Ando, K. Ikeda, M. Lee, and A. Bahadori, "A Neural Network-Based Local Rainfall Prediction System Using Meteorological Data on the Internet: A Case Study Using Data from the Japan Meteorological Agency," *Applied Soft Computing Journal*, vol. 56, pp. 317–330, Jul. 2017. doi: 10.1016/j.asoc.2017.03.015
- [6] V. P. Tharun, R. Prakash, and S. R. Devi, "Prediction of Rainfall Using Data Mining Techniques," in *Proceedings of the International Conference on Inventive Communication and Computational Technologies, ICICCT 2018*, Institute of Electrical and Electronics Engineers Inc., Sep. 2018, pp. 1507–1512. doi: 10.1109/ICICCT.2018.8473177
- [7] J. S. A. N. W. Premachandra, and P. P. N. V. Kumara, "A Novel Approach for Weather Prediction for Agriculture in Sri Lanka Using Machine Learning Techniques," in *Proceedings - International Research Conference on Smart Computing and Systems Engineering, SCSE 2021*, Institute of Electrical and Electronics Engineers Inc., Sep. 2021, pp. 182–189. doi: 10.1109/SCSE53661.2021.9568319
- [8] U. Shah, S. Garg, N. Sisodiya, N. Dube, and S. Sharma, "Rainfall Prediction: Accuracy Enhancement Using Machine Learning and Forecasting Techniques," in *PDGC 2018 - 2018 5th International Conference on Parallel, Distributed and Grid Computing*, Institute of Electrical and Electronics Engineers Inc., Dec. 2018, pp. 776–782. doi: 10.1109/PDGC.2018.8745763
- [9] L. C. Jain and L. R. Medsker, *Recurrent Neural Networks*, 1999. doi: 10.1201/9781420049176
- [10] X. H. Le, H. V. Ho, G. Lee, and S. Jung, "Application of Long Short-Term Memory (LSTM) Neural Network for Flood Forecasting," *Water (Switzerland)*, vol. 11, no. 7, 2019. doi: 10.3390/w11071387
- [11] S. S. Gumaste and A. J. Kadam, "Future Weather Prediction Using Genetic Algorithm and FFT for Smart Farming." *2016 International Conference on Computing Communication Control and automation (ICCUBE)*, Pune, India, 2016, pp. 1–6. doi: 10.1109/ICCUBE.2016.7860028
- [12] F. Najib and I. W. Mustika, "Weather Forecasting Using Artificial Neural Network for Rice Farming in Delanggu Village," in *IOP Conference Series: Earth and Environmental Science*, Institute of Physics, 2022. doi: 10.1088/1755-1315/1030/1/012002
- [13] C. Nyasulu, A. Diattara, A. Traore, A. Deme, and C. Ba, "Towards Resilient Agriculture to Hostile Climate Change in the Sahel Region: A Case Study of Machine Learning- Based

- Weather Prediction in Senegal,” *Agriculture (Switzerland)*, vol. 12, no. 9, Sep. 2022. doi: 10.3390/agriculture12091473
- [14] H. Kerner, M. Alamaniotis, and C. J. Talsma, “Frost Prediction Using Machine Learning and Deep Neural Network Models.”
- [15] S. Hochreiter, and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780. 1997. doi: 10.1162/neco.1997.9.8.1735
- [16] P. J. Werbos, “Generalization of Backpropagation with Application to a Recurrent Gas Market Model,” *Neural Networks*, vol. 1, no. 4, pp. 339–356, 1988. doi: 10.1016/0893-6080(88)90007-X
- [17] Home. (n.d.). Accessed: Aug. 07, 2023. <https://data.gov.in/catalog/climatology-data-important-cities-0>
- [18] “Welles Wilder - New Concepts in Technical Trading Systems | PDF | Algorithmic Trading | Financial Economics.” Accessed: Aug. 09, 2023. [Online]. Available: <https://www.scribd.com/doc/53093880/Welles-Wilder-New-Concepts-in-Technical-Trading-Systems#>
- [19] F. K. Oduro-Gyimah, and K. O. Boateng, “Forecasting Abilities of MIMO and SISO Neural Networks: A Comparative Study Using Telecommunication Traffic Data,” in *Proceedings - 2019 International Conference on Computing, Computational Modelling and Applications, ICCMA 2019*, Institute of Electrical and Electronics Engineers Inc., Mar. 2019, pp. 81–86. doi: 10.1109/ICCMA.2019.00020
- [20] S. N. H. Bukhari, J. Webber, and A. Mehbodniya, “Decision Tree Based Ensemble Machine Learning Model for the Prediction of Zika Virus T-Cell Epitopes as Potential Vaccine Candidates,” *Scientific Reports*, vol. 12, pp. 7810, 2022. doi: 10.1038/s41598-022-11731-6
- [21] G. S. Raghavendra, S. Shyni Carmel Mary, Purnendu Bikash Acharjee, V. L. Varun, Syed Nisar Hussain Bukhari, Chiranjit Dutta, and Issah Abubakari Samori, “An Empirical Investigation in Analysing the Critical Factors of Artificial Intelligence in Influencing the Food Processing Industry: A Multivariate Analysis of Variance (MANOVA) Approach,” *Journal of Food Quality*, vol. 2022, Article ID 2197717, 7 pages, 2022. doi: 10.1155/2022/2197717
- [22] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya, and J. Webber, “Ensemble Machine Learning Model to Predict SARS-CoV-2 T-Cell Epitopes as Potential Vaccine Targets,” *Diagnostics*, vol. 11, no. 11, 1990. MDPI AG. Retrieved from doi: 10.3390/diagnostics11111990
- [23] Sunil L. Bangare, Deepali Virmani, Girija Rani Karetla, Pankaj Chaudhary, Harveen Kaur, Syed Nisar Hussain Bukhari, and Shahajan Miah, “Forecasting the Applied Deep Learning Tools in Enhancing Food Quality for Heart Related Diseases Effectively: A Study Using Structural Equation Model Analysis,” *Journal of Food Quality*, vol. 2022, Article ID 6987569, 8 pages, 2022. doi: 10.1155/2022/6987569
- [24] C. M. Anoruo, S. N. H. Bukhari, and O. K. Nwofor, “Modeling and Spatial Characterization of Aerosols at Middle East AERONET Stations,” *Theoretical and Applied Climatology*, vol. 152, pp. 617–625, 2023. doi: 10.1007/s00704-023-04384-6

- [25] F. Masoodi, M. Quasim, S. Bukhari, S. Dixit, and S. Alam, *Applications of Machine Learning and Deep Learning on Biological Data*, CRC Press, 2023.
- [26] S. N. H. Bukhari, A. Jain, and E. Haq, “A Novel Ensemble Machine Learning Model for Prediction of Zika Virus T-Cell Epitopes,” in Gupta, D., Polkowski, Z., Khanna, A., Bhattacharyya, S., and Castillo, O. (Eds.), *Proceedings of Data Analytics and Management. Lecture Notes on Data Engineering and Communications Technologies*, vol 91. Springer, Singapore, 2022. doi: 10.1007/978-981-16-6285-0_23
- [27] S. N. H. Bukhari, F. Masoodi, M. A. Dar, N. I. Wani, A. Sajad, and G. Hussain, “Prediction of Erythematous-Squamous Diseases Using Machine Learning” in *Auerbach Publications eBooks*, pp. 87–96, 2023. doi: 10.1201/9781003328780-6
- [28] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya, & J. Webber, “Machine Learning Techniques for the Prediction of B-Cell and T-Cell Epitopes as Potential Vaccine Targets with a Specific Focus on SARS-CoV-2 Pathogen: A Review,” *Pathogens*, vol. 11, no. 2, p. 146, 2022. MDPI AG. doi: 10.3390/pathogens11020146
- [29] S. Nisar, H. Bukhari, and M. A. Dar, “Using Random Forest to Predict T-Cell Epitopes of Dengue Virus,” *Advances and Applications in Mathematical Sciences*, vol. 20, no. 11, pp. 2543–2547, 2021