

CHƯƠNG 9: DỰ ĐOÁN NĂNG SUẤT CÂY TRỒNG NÔNG NGHIỆP: PHÂN TÍCH SO SÁNH SỬ DỤNG CÁC MÔ HÌNH HỌC MÁY

Kukatlapalli Pradeep Kumar, S. Babu Kumar, Amarthya Dutta Gupta, Kevin Johnson, và Meghan Mary Michael

CHRIST (Đại học được công nhận), Cơ sở Kengeri, Bangalore, Ấn Độ

9.1 GIỚI THIỆU

Nền kinh tế của các quốc gia mới nổi như Ấn Độ được hưởng lợi rất lớn từ nông nghiệp, một trong những hình thức cư trú phổ biến nhất. Khoảng **200.2 triệu ha** đất được sử dụng cho nông nghiệp ở Ấn Độ, là một nguồn thu nhập đáng kể. Ở Ấn Độ, **70%** dân số sống dựa vào nông nghiệp. Nền kinh tế của chúng ta đang chịu áp lực phải tăng sản lượng lương thực do dân số quá đông. Trong những năm gần đây, đã có một mong muốn rộng rãi về sự phát triển trong nhiều ngành công nghiệp do sự phát triển nhanh chóng của công nghệ thông tin. Nông nghiệp là một trong những lĩnh vực có nhiều không gian để phát triển.

Hạn chế này chủ yếu là do thiếu một mô hình nông nghiệp đáng tin cậy và sự hướng dẫn đầy đủ cho nông dân. Việc thực hiện các ứng dụng nông nghiệp thông minh ở các làng biệt lập của Ấn Độ là vô cùng khó khăn, đặc biệt là khi nói đến việc đáp ứng nhu cầu cộng đồng. Ví dụ, những người dân thất học và nghèo khó trồng lúa bằng các phương pháp truyền thống. Nông dân sẽ thấy dễ đưa ra quyết định hơn nếu có một cơ chế có thể **tự động hóa việc tưới tiêu, xác định chất lượng đất, và dự báo điều kiện thời tiết** cũng như **giá cả**. Nông nghiệp phải được phát triển mạnh mẽ thông qua các đổi mới trong kỷ nguyên số hóa này nếu muốn tiếp cận với những nông dân nhỏ lẻ và bị **thiệt thòi**.

Nhiều vụ mùa bị thất thu hàng năm do chuyên môn kỹ thuật không đầy đủ và các mô hình thời tiết không lường trước được, như **biến động nhiệt độ** và **lượng mưa**, có ảnh hưởng đáng kể đến **năng suất nông nghiệp** và **doanh thu**.

Dự đoán năng suất cây trồng (CYP) là một trách nhiệm quan trọng đối với các yếu tố nông nghiệp. Việc quản lý các yếu tố nông nghiệp và đảm bảo sản lượng cao nhất phụ thuộc rất nhiều vào dự đoán năng suất cây trồng (CYP). CYP chủ yếu tập trung vào hai bộ tính năng quan trọng nhất.

Theo nông dân, một bộ dữ liệu bao gồm các phương pháp được sử dụng để:

- **tưới tiêu**
- **bón phân**
- **chuẩn bị đồng ruộng**

Một bộ dữ liệu khác bao gồm các biến môi trường được chi phối bởi thiên nhiên, chẳng hạn như:

- **bức xạ mặt trời**
- **nhiệt độ**
- **lượng mưa**

Sự giao tiếp với các phương pháp quản lý đồng ruộng và các yếu tố môi trường ảnh hưởng đến cách hành xử của các **marker di truyền**. Số lượng biến số tuyệt đối phải được xem xét làm cho việc dự đoán năng suất cây trồng với bất kỳ mức độ chính xác nào trở nên gần như không thể.

Nông nghiệp chính xác, bao gồm dự đoán năng suất nông nghiệp, có một số lợi thế, bao gồm:

- **tăng cường sản lượng và chất lượng cây trồng**
- **giảm thiểu tác động môi trường**

Việc sử dụng các mô phỏng năng suất cây trồng giúp dễ dàng hiểu được các tác động tổng hợp của **thiếu hụt chất dinh dưỡng và nước, bệnh tật, sâu bệnh, và các biến số khác** trong đồng ruộng trong suốt mùa sinh trưởng. Điều này có thể dẫn đến các phương pháp nông nghiệp có ý thức về môi trường mà còn mang lại lợi ích cho xã hội nói chung.

Năng suất cây trồng có thể khó dự báo hơn do **tương tác giữa kiểu gen và các biến môi trường**. Rất khó để dự đoán chính xác **ảnh hưởng phi tuyến phức tạp** của các tác động bên ngoài, bao gồm cả thời tiết. Ngoài ra, khi đưa ra các quyết định tài chính, nông dân và người trồng trọt đều tính đến **dự báo cây trồng**. Hai trở ngại lớn nhất trong kỷ nguyên nông nghiệp số hiện tại là **thu thập dữ liệu** và **tích hợp dữ liệu**.

Học máy (ML), một tập hợp con của AI, tập trung vào học hỏi, và đó là một quá trình tự phát cung cấp CYP tốt nhất, tùy thuộc vào một số yếu tố. Phương pháp ML phân tích một bộ dữ liệu để tìm thông tin, mô hình và các mối liên hệ. Bộ dữ liệu nên được sử dụng để đào tạo thuật toán để kết quả có thể được dự đoán dựa trên kiến thức trước đó. Kỹ thuật dự đoán được xây dựng bằng cách sử dụng nhiều đặc điểm khác nhau; ví dụ, các tham số mô hình có thể được xác nhận bằng cách sử dụng dữ liệu từ việc học. Dựa trên các tính năng được trình bày, ML là một kỹ thuật thực tế giúp cải thiện dự báo sản lượng nông nghiệp.

Nhiều nghiên cứu đã sử dụng các kỹ thuật ML để phân loại CYP, bao gồm:

- **rừng ngẫu nhiên (random forests)**
- **cây hồi quy (regression trees)**
- **hồi quy đa biến (multivariate regression)**

Bằng cách phân tích dữ liệu trong quá khứ, chúng ta có thể chọn các tham số của mô hình dự đoán trong giai đoạn đào tạo sau. Việc đánh giá tính đến một phần dữ liệu trước đó.

Nhiều kỹ thuật, bao gồm **phân loại** và **phân cụm**, được sử dụng cho dự đoán. Thông tin được lấy ra từ dữ liệu.

Các doanh nghiệp nông nghiệp có thể quản lý các lựa chọn chuỗi cung ứng như **lập kế hoạch sản xuất** bằng cách sử dụng các dự báo sản xuất cây trồng và rủi ro chính xác. Dự báo sản lượng cây trồng đóng vai trò là nền tảng cho **tiếp thị**. Nhận dạng và lập bản đồ cây trồng được hưởng lợi từ việc sử dụng **hình ảnh đa thời gian**, điều này giúp có thể phân loại chi phí bằng cách tính đến sự khác biệt trong **độ phản xạ loại cây trồng**. Sử dụng các chỉ số năng suất nông nghiệp để xác định các vấn đề sớm và áp dụng các giải pháp có thể **tăng sản lượng cây trồng và lợi nhuận**. Một phát triển mới là việc sử dụng **mô hình lai (hybrid models)**, kết hợp nhiều phương pháp ML để **tăng độ chính xác**.

Học sâu (Deep learning), một nhánh của ML, sử dụng **mạng nơ-ron nhân tạo (ANNs)** với nghiên cứu về các biểu diễn. Trong sự hiện diện của dữ liệu phức tạp, chẳng hạn như **các nhóm và vùng trưởng thành, chi tiết di truyền, và các điều kiện khí tượng khác nhau**, các phương pháp học sâu có thể cung cấp câu trả lời. Kỹ thuật này có thể học hỏi cực kỳ hiệu quả các **mối quan hệ phi tuyến** giữa năng suất dự kiến cùng với dữ liệu đa biến được nhập vào (**thông tin cụm, yếu tố khí tượng, và nhóm trưởng thành**). **Mạng Bộ nhớ Ngắn-Dài Hạn (LSTM)**, rất hữu ích cho mô hình hóa chuỗi thời gian, có thể nắm bắt **sự phụ thuộc tạm thời dài hạn** trong các chuỗi đa biến đầy thách thức. Tiềm năng dự đoán của các mô hình ML cũng có thể được tăng lên bằng cách **kết hợp dữ liệu từ các nguồn khác**, chẳng hạn như **lập bản đồ 3D, dữ liệu điều kiện xã hội dựa trên cảm biến, và dữ liệu màu đất dựa trên drone**.

9.2 ĐÁNH GIÁ TÀI LIỆU

Năng suất cây trồng là một chủ đề có tầm quan trọng lớn về kinh tế và toàn cầu. Nó có thể giúp quản lý tài nguyên nông nghiệp một cách hiệu quả và đảm bảo an ninh lương thực. Những tiến bộ trong CYP có thể thúc đẩy nền kinh tế của một quốc gia và giúp ích trong quá trình ra quyết định của nông dân đối với việc **trồng trọt, thu hoạch và phân bổ nguồn lực**. Các bài báo văn học này đóng vai trò là nền tảng cho chương này, nhằm mục đích đưa ra một mô hình có thể phát triển thêm các kết quả và quan sát từ các nghiên cứu này. Phần này của chương trình bày các nghiên cứu đã tồn tại được thực hiện trên CYP bằng cách sử dụng các mô hình khác nhau như **học sâu, mạng nơ-ron (NN), và mô hình ML**.

9.2.1 Mạng Nơ-ron

Inam Ali và cộng sự [6] tìm thấy **mối tương quan giữa các thuộc tính từ dữ liệu lúa hiện có** và triển khai các phương pháp dựa trên **ML và phân tích** cho CYP. Nghiên cứu tập trung vào dữ liệu thu được từ **quận Larkana ở Pakistan**, nơi chưa từng được nghiên cứu trước đây từ khía cạnh năng suất nông nghiệp. Khu vực nông nghiệp ở Pakistan đóng góp đáng kể vào nền kinh tế của đất nước. Nghiên cứu cho thấy rằng bằng cách sử dụng **thuật toán Apriori** trên bộ dữ liệu cây lúa của Larkana, các nhà nghiên cứu đã có thể

chia sẻ các dự đoán năng suất quan trọng, có thể được mở rộng rộng rãi sang các cây trồng khác bằng cách thay đổi các thuộc tính cụ thể. Dữ liệu được sử dụng cho nghiên cứu được thu thập từ các phòng ban liên quan tại địa phương khác nhau. Bộ dữ liệu năng suất lúa cuối cùng chứa các tham số mục tiêu: **năm, năng suất, độ ẩm, tốc độ gió, nhiệt độ lượng mưa và diện tích**. Dữ liệu thu thập chứa dữ liệu cho các tham số đã đề cập trong khoảng thời gian **sáu năm**. Phương pháp NN đã được sử dụng để tối ưu hóa dữ liệu năng suất lúa, vì nó rất quan trọng và được ưa chuộng do mức độ chính xác của nó được chấp nhận. NNs đã được sử dụng để **tối ưu hóa kết quả dự đoán năng suất lúa**, cung cấp năng suất giá trị cao sẽ mang lại lợi ích cho nông dân, các nhà nông học địa phương và các quan chức chính phủ để đưa ra quyết định dựa trên cây lúa. Họ có thể đánh giá các giá trị dự báo của các biến được kết nối được nêu trong nghiên cứu và sử dụng dữ liệu này, cùng với các mô hình lịch sử, để đưa ra các quyết định dựa trên dữ liệu tốt hơn. Kết quả của nghiên cứu có thể củng cố nền kinh tế của đất nước bằng cách **tăng sản xuất lúa** và cũng hỗ trợ **ngăn ngừa tổn thất tiền tệ** phát sinh bởi nông dân.

Trong nghiên cứu của Gopi và cộng sự [7], NNs, cụ thể là một **mạng nơ-ron hồi quy tổ hợp (ERNN)**, được sử dụng với kỹ thuật **Tối ưu hóa Cáo Đỏ (RFO)** cho lời khuyên về cây trồng và dự báo năng suất. Canh tác chính xác được hưởng lợi từ việc **tăng chất lượng và năng suất cây trồng mà không có tác động tiêu cực đến môi trường**. Nó tập trung vào **giám sát các phản ứng đối với sự biến đổi giữa và trong nội bộ** trong các hệ thống nông nghiệp, hệ thống thông tin quản lý, công nghệ tỷ lệ biến đổi, và những thứ khác. Nông dân sử dụng các mô hình canh tác truyền thống để đưa ra các quyết định liên quan đến sản xuất và trồng trọt cây trồng, nhưng để hỗ trợ tạo ra các đánh giá dựa trên dữ liệu sau khi tính đến các khía cạnh biến đổi, **một hệ thống khuyến nghị cây trồng tự động** là cần thiết. Một bộ dữ liệu dự báo năng suất và lời khuyên cây trồng từ kho lưu trữ Kaggle đã được sử dụng để xác nhận kỹ thuật **RFOERNN-CRYP** bằng thực nghiệm. Kỹ thuật này sẽ giúp nông dân bằng cách hỗ trợ họ trong quá trình ra quyết định bằng cách tính đến các tham số nông nghiệp liên quan khác nhau. Phương pháp **RFO** được sử dụng trong quy trình **lựa chọn siêu tham số**, giúp **cải thiện hiệu suất** của quy trình học tổ hợp. Điều này cũng đảm bảo rằng **độ chính xác của mô hình được duy trì từ gốc**. Thông qua việc thực hiện nhiều phân tích thử nghiệm, người ta thấy rằng kết quả của **RFOERNN-CRYP là lạc quan**, với điểm R^2 tối đa là **0.9988** và độ chính xác là **98.45%**. Mô hình được đề xuất trong nghiên cứu có thể được thử nghiệm trên các bộ dữ liệu thực tế, lớn hơn trong tương lai. Ngoài ra, phạm vi sử dụng **học sâu và mô hình phát hiện kiểu hình cây trồng dựa trên công nghệ thị giác máy tính** sẽ trở nên khả thi.

Muthukumaran và cộng sự [8] tìm cách **cải thiện năng suất lúa** bằng cách sử dụng các **kỹ thuật tính toán tiến hóa** để dự đoán bản chất của các yếu tố ảnh hưởng đến tốc độ tăng trưởng với ý định **cải thiện an ninh lương thực**. Các nhà nghiên cứu tập trung vào **phân tích tác động thực tế, hàng ngày của các hiện tượng khí tượng, tốc độ gió, hướng gió và độ ẩm tương đối** thay vì dựa vào hồ sơ lịch sử. Một **Thuật toán ROANN** đã được sử dụng để dự đoán, và **Thuật toán Tối ưu hóa Đàn hạt Đa mục tiêu** và **Thuật toán Di truyền** đã được sử dụng để **tối ưu hóa các tham số đầu vào và tái cấu trúc cơ sở dữ liệu**. Người ta quan sát thấy rằng thuật toán ROANN được đề xuất dự đoán các yếu

tổ mà nông dân cần tập trung vào trong khi **tương quan các hiện tượng khí tượng khác nhau**. Các kỹ thuật tối ưu hóa đã thành công trong việc **xác định các tham số đầu vào** từ bộ dữ liệu thời gian thực. Độ chính xác tối đa và tỷ lệ lỗi tối thiểu đã được quan sát khi **điều chỉnh các tham số NN** với các lớp ẩn và tốc độ học.

Một bài báo của Vignesh và cộng sự [9] nhằm mục đích dự đoán năng suất cây trồng bằng cách sử dụng **Visual Geometry Group (VGG)** và **Discrete Deep Belief Network** với phương pháp phân loại mạng để tạo ra các hệ thống CYP để kết nối dữ liệu thô với dự đoán năng suất cây trồng. Để đạt được điều này, các nhà nghiên cứu đã thu thập **các tham số dữ liệu từ trang web nông nghiệp nhà nước của Ấn Độ**, đóng vai trò là nền tảng cho mô hình dự đoán của họ. Các tham số dữ liệu được thu thập từ trang web nông nghiệp đã được đưa vào mạng, bao gồm nhiều lớp xếp chồng lên nhau. Các lớp này xử lý các tham số đầu vào một cách tuần tự, cuối cùng hình thành một **khuôn khổ toàn diện** cho dự đoán sản lượng cây trồng. Để tối ưu hóa dữ liệu đầu vào cho kết quả hiệu quả nhất, các nhà nghiên cứu đã sử dụng một kỹ thuật gọi là **“tối ưu hóa đàn gà con tinh chỉnh (tweak chick swarm optimization)”**. Phương pháp tối ưu hóa này **tinh chỉnh và tiền xử lý dữ liệu đầu vào**, đảm bảo rằng các đặc điểm liên quan và có giá trị nhất được trích xuất. Dữ liệu tinh chỉnh thu được sau đó được đưa vào quy trình phân loại như là đầu vào. Để thực hiện phân loại thực tế và dự đoán năng suất nông nghiệp, các nhà nghiên cứu đã sử dụng cả **Discrete Deep Belief Network** và **VGG Net Classifier**. Kết quả của phương pháp của họ rất ấn tượng, **vượt qua các phương pháp trước đó về độ chính xác dự đoán**. Cụ thể, mô hình này đạt được **tỷ lệ chính xác ấn tượng là 97%**, nhấn mạnh sự thành thạo của nó trong việc **chọn các loại cây trồng có khả năng mang lại lợi nhuận cao nhất**.

9.2.2 Thuật toán Tối ưu hóa

Nghiên cứu của Mohsen Yoosefzadeh và cộng sự [10] nhằm mục đích **cải thiện tiềm năng năng suất di truyền** trong cây đậu nành, một loại cây trồng cấp thực phẩm chính có thể là giải pháp bền vững nhất để giải quyết các mối lo ngại về an ninh lương thực ngày càng tăng và nhu cầu toàn cầu. Năm đặc điểm đầu tiên được xác định là các thuộc tính thành phần năng suất đậu nành quan trọng nhất đã được đánh giá. **Các thuật toán ML** đã được sử dụng cả riêng lẻ và cùng nhau trên dữ liệu được chọn thông qua **phương pháp tổ hợp sử dụng thuật toán Random Forest (RF), Multilayer Perceptron (MLP) và Radial Basis Function (RBF)**. Trong số các kỹ thuật này, **thuật toán RBF là hiệu quả nhất với hệ số xác định (R^2) là 0.81** và **sai số tuyệt đối trung bình (MAE) thấp hơn là $148.61 kg.ha^{-1}$** cùng **giá trị lỗi căn bậc hai trung bình (RMSE) là $185.31 kg.ha^{-1}$** . RBF đã được chọn làm bộ phân loại phụ cho thuật toán E-B. Các phương pháp lai tạo có thể được sửa đổi để **cải thiện triển vọng di truyền của các đặc điểm phức tạp**, chẳng hạn như năng suất dựa trên các thuộc tính thứ cấp chi phối hiệu quả và kết quả cuối cùng. Mặc dù kết quả của nghiên cứu là hứa hẹn, việc đo lường các thành phần năng suất **tốn nhiều công sức** và, do đó, **không thể áp dụng cho các triển khai quy mô lớn** và do đó **hạn chế việc sử dụng chiến lược này cho các sáng kiến phát triển giống cây trồng**. Nghiên cứu sẽ giúp các nhà lai tạo **chọn dòng bố mẹ và**

thực hiện các phép lai tạo hiệu quả, hai quy trình quan trọng đối với các nhà lai tạo đang tìm cách phát triển các giống cây trồng có tiềm năng sản xuất di truyền cao hơn.

Dự đoán năng suất xem xét các loại tưới tiêu khác nhau là lý tưởng để **tối ưu hóa tài nguyên**. CYP đóng một vai trò không thể thiếu trong việc đạt được **lịch trình tưới tiêu và đánh giá các yêu cầu lao động cho việc lưu trữ và thu hoạch**. Độ chính xác của CYP đòi hỏi một sự hiểu biết logic chi tiết về **tính tương đối giữa năng suất và các yếu tố hợp tác**. Để đạt được kết nối này, **các bộ dữ liệu lớn và một mô hình hiệu quả** là cần thiết. Học sâu đã được sử dụng trong nghiên cứu này [11] để **đánh giá và phân tích dữ liệu phức tạp** như kiểu gen, các tham số thời tiết, các nhóm trưởng thành, v.v.. Một **Dự đoán Năng suất Cây trồng Tự động (ACYP)** sử dụng **Mô hình Tối ưu hóa Chính trị Hỗn loạn với Học sâu (CPODL)** được đề xuất. Các bước liên quan trong kỹ thuật ACYP-CPODL là **tiền xử lý và tối ưu hóa tham số**. Đối với mô hình này, việc **điều chỉnh siêu tham số** là bằng **thuật toán CPO**. Kỹ thuật này đã có thể đạt được và tạo ra các kết quả thành công hợp lý với **sai số trung bình bình phương (MSE) là 0.031 và điểm R^2 là 0.936**. Tuy nhiên, cần lưu ý rằng **mô hình Bidirectional Long Short-Term Memory (BLSTM)** cũng đã có thể tạo ra các kết quả phản ánh mô hình đã đề cập ở mức độ tốt. Một loạt các mô phỏng rộng hơn trên các bộ dữ liệu chuẩn đã cho thấy rằng trong một nghiên cứu so sánh, **sự cải thiện trong các dự đoán được thực hiện bởi mô hình ACYP-CPODL được xác nhận và xác minh là đúng**. Nó đã chứng minh thành công như một kỹ thuật để **ước tính năng suất nông nghiệp**. Việc thiết kế các mô hình dự đoán dựa trên kết hợp sẽ cải thiện kết quả dự đoán trong tương lai.

Bài báo được tham chiếu là [12] tìm cách khai thác **dữ liệu rộng lớn được thu thập bởi các cơ sở quan sát Trái đất (EO)** để phát triển một mô hình có thể **nâng cao dự đoán năng suất cây trồng**. Để đạt được điều này, nghiên cứu tận dụng **dữ liệu EO có nguồn gốc từ vệ tinh Sentinel-2 và Landsat-8 để tính chỉnh các tham số của mô hình APSIM-Maize**. Để giải quyết các **sự không chắc chắn cố hữu** liên quan đến các **thuộc tính đất, các biến khí tượng và các thực hành quản lý không rõ**, một **phương pháp lấy mẫu Monte-Carlo** đã được sử dụng. Cách tiếp cận này cho phép các nhà nghiên cứu **tính đến và truyền bá các sự không chắc chắn này một cách hiệu quả**. Cụ thể, sử dụng cả **giá trị trung bình và các biện pháp không chắc chắn** được lấy từ bộ dữ liệu lưới đất, nghiên cứu đã tạo ra **25 biểu diễn hoặc tổ hợp thay thế của hồ sơ đất** cho mỗi địa điểm, do đó nắm bắt được **sự biến đổi trong các thuộc tính đất**. Nghiên cứu đã sử dụng dữ liệu được thu thập từ **hai vệ tinh EO chính, Sentinel-2 và Landsat-8, cho mục đích hiệu chuẩn**. Sentinel-2 cung cấp các quan sát có giá trị về **Chỉ số Diện tích Lá (LAI)**, trong khi Landsat-8 đóng góp dữ liệu liên quan đến **Chỉ số Thực vật Khác biệt Chuẩn hóa (NDVI)**. Các biến cụ thể này đã được chọn vì nghiên cứu trước đây đã chứng minh **sức mạnh dự đoán mạnh mẽ** của chúng liên quan đến năng suất cây trồng. Phân tích này rất quan trọng trong việc **xác định các tham số trong mô hình APSIM** mà gây ra **ảnh hưởng đáng kể nhất** đến dự đoán LAI ngô. Bằng cách đánh giá một cách có hệ thống **độ nhạy của các tham số này**, nghiên cứu tìm cách **tăng cường độ chính xác và độ tin cậy** của CYP trong mô hình APSIM-Maize.

Theo tác giả [13], việc sản xuất nông nghiệp liên quan đến một lượng **sự không chắc chắn đáng kể**; do đó, **không có cách tiếp cận nào có thể dự đoán đầy đủ kết quả cuối cùng**. Hạn chế này có thể được khắc phục bằng cách **tích hợp tối ưu hóa trí tuệ bầy đàn** với **hàm ảnh hưởng của phân bón** để trình bày nhiều khả năng về kết quả xác nhận trong các cài đặt ngẫu nhiên khác nhau. Phương pháp này **thực tế hơn các phương pháp thông thường như hồi quy**. Người ta nhấn mạnh rằng các **hạn chế cần thiết cho phương pháp [13] này sẽ mở rộng** khi thuật toán được áp dụng trong một **cài đặt thể giới thực**, có lẽ làm cho kết quả **lệch lạc** nhưng không đủ để ảnh hưởng đến ứng dụng của phương pháp. Để đáp ứng các mục tiêu của quản lý khoa học, công việc tiếp theo về phương pháp sẽ tập trung vào việc **nghiên cứu một bộ các mô hình bón phân được xác định trước**. Người ta lưu ý rằng thuật toán **hoạt động tốt trong việc giải hệ số phương trình, khớp và giải pháp năng suất tối đa**. Các phát hiện đã chứng minh một **mức độ khớp tăng lên** trong phương trình tác động của phân bón có khả năng **dự báo hợp lý tỷ lệ bón phân chính xác và cải thiện năng suất**.

Tầm quan trọng của dự đoán sản lượng cây trồng trong ngành nông nghiệp được thừa nhận trong bài báo này [147]. Nó dự định sử dụng các **phương pháp ML nổi tiếng**, bao gồm **bộ nhớ ngắn hạn dài (LSTM)** và **mạng nơ-ron tích chập (CNN)**. Để ước tính năng suất cho các cây trồng nhất định, nó **kết hợp cả hai mô hình đó**. Bộ dữ liệu được sử dụng trong nghiên cứu này bao gồm thông tin về **lượng mưa từ năm 1901 đến năm 2020**, cũng như thông tin năng suất nông nghiệp cho **bông, ngô, kê, lúa và mía**. Các bộ dữ liệu này được thu thập từ trang web của chính phủ Ấn Độ. Để sử dụng tất cả dữ liệu này một cách hiệu quả trong nghiên cứu này, nó đã được **tích hợp và tiền xử lý**. **Hàm tối ưu hóa cải tiến (IOF)** làm **giảm lỗi** và **hội tụ nhanh** tùy thuộc vào sự lan truyền ngược được sử dụng. Sau khi chạy các mô hình, các **số liệu hiệu suất** sau đây đã được sử dụng để đánh giá:

- Sai số phần trăm tuyệt đối trung bình (MAPE) - 0.836 đến 1.245
- MAE - 0.054 đến 2.321
- RMSE - 0.071 đến 2.321
- ** R -squared điều chỉnh** - 0.964 đến 0.977

9.2.3 Viễn thám và Hình ảnh

Bài báo này [16] đề cập đến việc sử dụng **Hình ảnh Đa phổ của Hệ thống Máy bay Không người lái (UAS)** để **dự đoán năng suất** và **tối ưu hóa tài nguyên đầu vào** cho cây ngô. Một UAS không người lái có thể được sử dụng để có được hình ảnh chứa **thông tin không gian và thời gian**, sẽ được sử dụng để phát triển một **mô hình thống kê để dự đoán năng suất** dựa trên các giai đoạn phát triển khác nhau. Nghiên cứu [16] đã được thực hiện tại **Trại Nghiên cứu Hệ thống Nông nghiệp W. B. Andrews ở Mississippi State, Mississippi, Hoa Kỳ**. Dữ liệu được sử dụng là từ **Trung tâm Thời tiết Nông nghiệp Delta**. Cánh đồng được chia thành các lô phụ, mỗi lô có các xử lý khác nhau để xác định lô nào là lý tưởng nhất cho cây ngô.

Bài báo này nhận ra **tầm quan trọng của CYP** trong lĩnh vực nông nghiệp. Nó nhằm mục đích sử dụng các **kỹ thuật ML phổ biến** như **mạng nơ-ron tích chập** và **bộ nhớ ngắn hạn dài**. Nó **kết hợp cả hai mô hình** đó để ước tính năng suất cho các cây trồng nhất định. Dữ liệu thu thập cho nghiên cứu này là một bộ dữ liệu chứa **dữ liệu lượng mưa từ năm 1901 đến năm 2020** và **dữ liệu năng suất cây trồng lúa, ngô, kê, mía và bông**. Các bộ dữ liệu này được thu thập từ **trang web của chính phủ Ấn Độ**. Tất cả dữ liệu này đã được **kết hợp và tiền xử lý** để được sử dụng hiệu quả trong nghiên cứu này. Bài báo đề xuất một **hàm tối ưu hóa nâng cao**, tức là **IOF**, để **giảm lỗi trong CYP**. Hàm IOF **giảm lỗi và hội tụ nhanh** tùy thuộc vào sự lan truyền ngược được sử dụng. Sau khi chạy các mô hình, các **số liệu hiệu suất** sau đây đã được sử dụng để đánh giá:

- **MAPE** - 0.836 đến 1.245
- **MAE** - 0.054 đến 2.321
- **RMSE** - 0.071 đến 2.321
- **R-squared điều chỉnh** - 0.964 đến 0.977

9.2.4 Lựa chọn Tính năng

Bài báo này [17] đề cập đến khía cạnh **lựa chọn tính năng để tối ưu hóa CYP**. Vì có nhiều yếu tố liên quan đến việc dự đoán năng suất cây trồng, việc **chọn những yếu tố cần thiết là quan trọng**, vì nhiều yếu tố ảnh hưởng đến năng suất cây trồng khác nhau.

Các thuật toán lựa chọn tính năng đã được sử dụng và các tính năng được chọn là:

- **Thuật toán Lựa chọn Tính năng Loại bỏ Lùi Tuần tự**: AH, CL, TK, OW, và Tmax
- **Thuật toán Lựa chọn Tính năng Dựa trên Tương quan**: AH, CL, TK, AT, Tmax, SD, NF, PF, và KF
- **Hệ số Lạm phát Phương sai**: AH, CL, TK, TW, OW, RainF, AT, Tmin, Tmax, và SR features (tính năng)
- **Hệ số Lạm phát Phương sai**: AH, CL, TK, TW, OW, RainF, AT, Tmin, Tmax, và R features (tính năng)
- **Độ quan trọng Biến RF**: AH, TK, OW, NF, PF, KF, và SD

Lấy **dự đoán phụ thuộc (PD)** làm tính năng phụ thuộc và **AH, OW, Tmax, TK, và CL** làm các tính năng độc lập, họ đã thực hiện **hồi quy tuyến tính đa biến**. Họ cũng đã sử dụng một ANN, lấy các tính năng độc lập làm lớp đầu vào và PD làm nơ-ron lớp đầu ra. **Độ chính xác của mô hình cuối cùng** được điều chỉnh bằng cách sử dụng **hệ số tương quan bình phương (R^2)** và đạt **85%** khi chỉ sử dụng các tính năng được chọn, trong khi khi sử dụng tất cả các tính năng, độ chính xác cuối cùng đạt **84%**. Điều này, do đó, có thể được sử dụng để kết luận rằng **thuật toán lựa chọn tính năng chuyển tiếp là tốt cho dự đoán tốt hơn**.

9.2.5 Tưới tiêu Chính xác

Bài báo này [18] đề cập đến việc đạt được **năng suất tối đa từ cây trồng** bằng cách sử dụng **công nghệ giữ nước dưới bề mặt (SWRT)**. Ở đây, chúng ta giải quyết quá trình **xác định năng suất cây trồng bằng cách sử dụng các thuật toán**. Chúng ta chủ yếu yêu cầu **hai yếu tố khác nhau** để xác định năng suất. Nghiên cứu này [18] được thực hiện do **mức độ ưu tiên cao** mà canh tác cây trồng bền vững có trong xã hội của chúng ta. Chúng ta cần sự **phối hợp tối ưu** của **thực phẩm, nước và năng lượng** để tiếp tục tiến lên. Vì nước đóng một vai trò rất lớn trong phát triển nông nghiệp, **việc sử dụng nước hiệu quả nhất** đóng một vai trò quan trọng trong việc **tối ưu hóa năng suất cây trồng**.

SWRT là một phương pháp được phát triển để **cải thiện khả năng giữ nước-đất** trong vùng rễ cây. Sử dụng **phần mềm HYDRUS-2D**, chúng ta tìm thấy **thiết kế màng và độ sâu lắp đặt thích hợp** trong điều kiện đất và thời tiết cụ thể trong **đất cát**. Thông qua các thử nghiệm khác nhau, người ta kết luận rằng **mô hình HYDRUS-2D có độ tin cậy cao và có độ chính xác đáng kể**. Mặc dù HYDRUS-2D có thể dự đoán sự **tích lũy nước và chất dinh dưỡng** tại vùng rễ cây, nó **không thể mô phỏng sự phát triển của cây trồng**. Để bù đắp cho thiếu sót này, chúng ta triển khai **phần mềm DSSAT** để cung cấp **thông tin chi tiết về năng suất cây trồng** từ hỗn hợp nước-đất cụ thể. Sử dụng mô hình toán học thích hợp và sử dụng đúng cả hai phần mềm, chúng ta có thể **thực hiện mô phỏng năng suất cây trồng dưới các màng SWRT khác nhau**. Các thử nghiệm và kết quả trong bài báo này [18] giúp chúng ta kết luận rằng việc sử dụng cả DSSAT và HYDRUS-2D, sẽ giúp **cắt giảm nỗ lực của con người trong việc tối ưu hóa các tham số nhất định**, điều này sẽ dẫn đến **tăng sản xuất cây trồng**.

9.3 PHƯƠNG PHÁP LUẬN


9.3.1 Tiền xử lý

Tiền xử lý đóng một vai trò quan trọng trong việc thiết kế một thuật toán ML, vì hầu hết các thuật toán yêu cầu dữ liệu để học hỏi và đưa ra dự đoán. Nếu dữ liệu không đạt yêu cầu, các dự đoán sẽ thực sự **không chính xác**.

Tiền xử lý chúng tôi đã thực hiện trong bộ dữ liệu được chọn bao gồm những điều sau đây:

1. Phân tích ngoại lai (Outlier Analysis)
2. Phân tích tương quan (Correlation Analysis)
3. Cập nhật giá trị bị thiếu (Updating Missing Values)
4. Mã hóa One-Hot (One-Hot Encoding)

Hình 9.1 là bản đồ nhiệt (heatmap) cho thấy **mối tương quan giữa tất cả các biến** trong bộ dữ liệu cuối cùng của chúng tôi.



Hình 9.1 Bản đồ nhiệt tương quan cho một tập hợp các thuộc tính đã cho.

Như chúng ta có thể thấy ở đây, chúng tôi đã lấy **năm biến** để phân tích, vì các biến khác đã bị loại bỏ vì không có đủ sự liên quan để mô hình được sử dụng. Vì tương quan nằm trong khoảng từ -1 đến 1 trong bản đồ nhiệt (**-1 cho thấy tương quan nghịch mạnh** và **1 cho thấy tương quan mạnh**), bỏ qua đường chéo trong ma trận, **thay đổi cao nhất xảy ra trong năng suất cây trồng tùy thuộc vào biến *pesticides_tonnes* (0.11)**.

9.3.2 Hồi quy Tuyến tính

Hồi quy tuyến tính có thể được định nghĩa là mối liên kết của một biến phụ thuộc với **một hoặc nhiều biến độc lập** được xác định bằng thống kê. Dựa trên giá trị đầu vào của một biến khác, nó có thể được sử dụng để **dự báo giá trị của một biến**. Trong trường hợp đã đề cập trước đó, biến có giá trị được tìm thấy được gọi là **biến độc lập**. **Biến phụ thuộc** là biến được sử dụng để ước tính giá trị của biến độc lập.

Hồi quy tuyến tính nhằm mục đích tìm ra **đường khớp nhất** có thể bao gồm các giá trị được dự đoán và mô tả mối liên kết giữa biến độc lập và các biến phụ thuộc. Nó thường được sử dụng để **ước tính xu hướng trong dữ liệu**. Nó là một kỹ thuật thống kê hiệu quả được sử dụng trong ML cho **phân tích dự đoán**. Biến phụ thuộc và biến độc lập được chứng minh là có **mối quan hệ tuyến tính**. Thông thường, các giá trị của các biến phụ thuộc nằm trên trục y cùng với các giá trị của các biến độc lập. Mô hình hồi quy tuyến tính được gọi là **hồi quy tuyến tính đơn giản** khi chỉ có **một biến đầu vào**.

Đường khớp nhất được tính bằng cách sử dụng **công thức chặn dốc truyền thống**, được đưa ra như sau:

$$Y_i = \alpha_0 + \alpha_1 X_i \quad (9.1)$$

Trong **Phương trình 9.1**, Y_i biểu thị **biến phụ thuộc** (đã được vẽ trên trục y trước đó), và X_i biểu thị **biến độc lập** được vẽ trên trục x. Các hệ số α_0 và α_1 lần lượt đại diện cho **giá trị hằng số/điểm chặn** và **độ dốc của đường khớp nhất**.

9.3.3 Hồi quy Đa thức

Trong một số trường hợp nhất định, các điểm được vẽ trên biểu đồ hồi quy x-y có thể là **phi tuyến tính** và, do đó, một đường thẳng khớp nhất duy nhất có thể không bao gồm hoặc tính đến tất cả các điểm. Để điều chỉnh kịch bản này, chúng ta yêu cầu **việc thực hiện các mô hình hồi quy đa thức**. Đó là, để khắc phục các điều kiện **underfitting** hoặc **overfitting** do việc sử dụng một đường thẳng làm đường khớp nhất, **hồi quy đa thức** được sử dụng. Hồi quy đa thức giúp xác định **mối liên kết cong tuyến tính** giữa các biến phụ thuộc và độc lập. Trong hồi quy đa thức, mối liên kết giữa các biến phụ thuộc và độc lập được mô hình hóa dưới dạng một **hàm đa thức bậc p**. Chỉ trong các điều kiện này, hồi quy đa thức mới có thể được thực hiện. Ngoài ra, người ta kỳ vọng rằng **các lỗi là ngẫu nhiên, phân bố đều với giá trị trung bình bằng không và phương sai là hằng số**.

Một số đặc điểm của hồi quy đa thức là:

- **Bậc của hàm có thể được thay đổi** để xác định đường khớp nhất cho một tập hợp các điểm đã cho
- Mô hình **đễ bị ảnh hưởng bởi các ngoại lai**, có thể ảnh hưởng đến kết quả

Công thức tiêu chuẩn cho hồi quy đa thức có thể được đưa ra như trong **Phương trình 9.2**.

$$g(y) = d_0 + d_1 y + d_2 y^2 + \dots + d_p y^p \quad (9.2)$$

Trong đó **p** là **bậc của đa thức** và **d** là **tập hợp các hệ số**.

Đối với bậc thấp hơn, mối quan hệ có tên cụ thể, tùy thuộc vào giá trị của p:

- Khi giá trị của **p** là **2**, nó được gọi là **mô hình hồi quy bậc hai (quadratic regression model)**
- Tương tự, khi giá trị của **p** là **3** và **4**, nó được gọi là **mô hình hồi quy bậc ba (cubic)** và **bậc bốn (quartic)**, tương ứng

Phương pháp **bình phương nhỏ nhất** thường được sử dụng để khớp các mô hình hồi quy đa thức, **giảm thiểu phương sai của các hệ số**. Việc **chọn đúng bậc (p)** cho một mô hình là **cần thiết** vì nó **ngăn chặn overfitting hoặc underfitting**.

9.3.4 XGBoost

XGBoost là viết tắt của **eXtreme Gradient Boosting**. Nó là một sản phẩm của **cây quyết định tăng cường gradient** có thể mang lại kết quả với **tốc độ và hiệu suất cao**. Nó hữu ích trong việc đạt được kết quả trên nhiều thách thức ML. Nó hoạt động phần lớn trên **gradient boosting**, là một **thuật toán học tổ hợp có giám sát**, trong đó nó cố gắng dự đoán giá trị bằng cách **kết hợp các ước tính của một tập hợp các mô hình đơn giản hơn, yếu hơn**.

Nó được ưa chuộng cao do khả năng **thao tác các bộ dữ liệu lớn đáng kể và hoạt động tốt trong các trường hợp liên quan đến hồi quy và phân loại**. Do khả năng **quản lý các giá trị bị thiếu mà không yêu cầu tiền xử lý đầu vào**, nó được yêu thích. Ngoài ra, nó bao gồm **chức năng xử lý song song tích hợp**, cho phép nó **đào tạo các mô hình nhanh chóng với các bộ dữ liệu lớn**.

Cây quyết định được xây dựng tuần tự trong thuật toán. **Trọng số** là một tham số quan trọng trong XGBoost. Trọng số được liên kết riêng lẻ với tất cả các biến độc lập; sau đó, chúng được đưa vào các cây quyết định, dự đoán kết quả. **Nhiều cây quyết định** được sử dụng để **tinh chỉnh các kết quả dự đoán** bằng cách đưa dữ liệu về phía trước; điều này được gọi là **học tổ hợp**. **Đạo hàm bậc nhất (gradient)** và **đạo hàm bậc hai (Hessian)** của hàm mất mát được tính cho mỗi điểm dữ liệu, như được mô tả trong **Phương trình 9.3 và 9.4**, tương ứng. Các giá trị này được sử dụng để **xây dựng các cây riêng lẻ và điều chỉnh mô hình**.

Gradient Hồi quy (g_i) cho MSE:

$$g_i = -2*(y_i - \hat{y}_i) \quad (9.3)$$

Hessian Hồi quy (h_i) cho MSE:

$$h_i = 2 \quad (9.4)$$

Quá trình điều chỉnh độ quy được thuật toán áp dụng làm cho nó **hiệu quả trong việc nắm bắt các mối quan hệ phức tạp với dữ liệu**, do đó làm cho nó **ngày càng chính xác hơn trong việc nắm bắt các mô hình và tương tác phi tuyến tính**. Nó sử dụng một **giá trị điều chuẩn** trong hàm mục tiêu của nó. XGBoost bao gồm các **thuật ngữ điều chuẩn L1 (Lasso) và L2 (Ridge)** để **kiểm soát độ phức tạp của các cây riêng lẻ và ngăn chặn overfitting**.

$$\text{Mục tiêu Điều chuẩn} = \text{Mục tiêu} + \text{Hình phạt}$$

Điều này là cần thiết trong việc **ngăn chặn overfitting**, là một điều kiện trong đó mô hình ML trở nên **quá phù hợp với dữ liệu đào tạo** đến mức nó không thể thích nghi với một bộ dữ liệu mới. Trong XGBoost, kỹ thuật điều chuẩn hỗ trợ trong việc **đảm bảo một mối tương quan mạnh mẽ giữa kết quả được tạo ra bởi mô hình đối với bộ dữ liệu đào tạo và bộ dữ liệu thử nghiệm**. Cách tiếp cận tổ hợp được áp dụng cũng cho phép thuật toán **khai thác sức mạnh của nhiều mô hình đồng thời giảm thiểu điểm yếu của**

chúng. XGBoost được ưa chuộng cao, vì nó là **phần mềm mã nguồn mở** trải qua quá trình **phát triển liên tục** bởi các chuyên gia đóng góp trong lĩnh vực này.

9.3.5 KNN

K-nearest neighbors, thường được gọi là **KNN**, là kỹ thuật ML thường được sử dụng cho các **vấn đề phân loại và hồi quy**. Nó là một **thuật toán dựa trên trường hợp** mà, không giống như các thuật toán khác, **không xây dựng một thuật toán rõ ràng** trong giai đoạn đào tạo của nó. Nó là một thuật toán dựa trên **kỹ thuật học có giám sát**. Thuật toán KNN **ghi nhớ toàn bộ bộ dữ liệu đào tạo** và, để phản hồi một điểm dữ liệu không xác định, **xác định vị trí K điểm gần nhất** trong bộ dữ liệu đào tạo và **gán giá trị mới cho lớp hoặc nhãn dựa trên một cuộc bỏ phiếu đa số hoặc một giá trị trung bình của k hàng xóm**. Điều này được thực hiện bằng cách sử dụng **khoảng cách Euclidean** cho các tính năng liên tục và **khoảng cách Hamming** cho các tính năng phân loại.

Khoảng cách Euclidean giữa hai điểm p và q trong một không gian d -chiều được thể hiện trong **Phương trình 9.5**:

$$\text{Khoảng cách Euclidean}(p, q) = \sqrt{\sum_{i=1}^d (P_i - q_i)^2} \quad (9.5)$$

Thuật toán có hai tham số - cụ thể là **K** và **độ đo khoảng cách**. **K** là **số lượng hàng xóm cần xem xét**. Nó là một **siêu tham số quan trọng** trong thuật toán, và việc **lựa chọn chính xác** của nó có thể **ảnh hưởng đáng kể đến hiệu suất** của thuật toán. **Độ đo khoảng cách** được sử dụng để tìm **sự giống nhau** giữa hai điểm dữ liệu đã cho. Mặc dù KNN là một thuật toán đơn giản, nó có một số hạn chế, chẳng hạn như **độ nhạy với giá trị của k**, **độ nhạy với việc lựa chọn độ đo khoảng cách**, và **sự kém hiệu quả về mặt tính toán với các bộ dữ liệu lớn**.

9.4 KẾT QUẢ VÀ THẢO LUẬN

Mục tiêu chính của phần này là trình bày các **kết quả của các thử nghiệm mô hình**. Sau khi các mô hình dự đoán khác nhau đã được đào tạo, chúng ta có thể sử dụng **Python 3.8.0** để chạy mô phỏng. Các kết quả nhất quán sẽ được tạo ra khi **số lượng thử nghiệm được tăng lên**. Kết quả là, chúng tôi sẽ đánh giá mức độ hiệu quả của các mô hình ML được nêu trong việc **dự đoán năng suất cây trồng nói chung** trong phần này.

9.4.1 Đánh giá Mô hình

- **Sai số Trung bình Bình phương (Mean Squared Error - MSE)**

MSE nổi lên như một **tham số quan trọng** làm sáng tỏ **hiệu quả dự đoán** của các mô hình ML được sử dụng trong nghiên cứu dự đoán sản lượng cây trồng này. Nó tính toán **sự khác biệt bình phương** giữa **năng suất cây trồng dự kiến** và **năng suất quan sát được** cho mỗi điểm dữ liệu trong bộ dữ liệu. Việc tính toán MSE bao gồm **tổng hợp tất**

cả các khác biệt bình phương này và sau đó lấy giá trị trung bình trên tất cả các điểm dữ liệu.


Về mặt toán học, quá trình này có thể được biểu thị như trong **Phương trình 9.6**:

$$MSE = \frac{1}{n} * \sum (năngsuấttthực - năngsuấtdựđoán)^2 \quad (9.6)$$

Trong ngữ cảnh này, biến “n” đại diện cho **tổng số điểm dữ liệu**.

Giá trị MSE thấp hơn cho thấy các mô hình - cụ thể là **XGBoost, hồi quy đa thức và KNN** - tạo ra các dự đoán **tương ứng chặt chẽ với năng suất cây trồng quan sát được**. MSE giảm cho thấy các mô hình **nắm bắt thành công các mô hình nội tại và sự biến động trong dữ liệu**, từ đó **tăng cường độ tin cậy tổng thể** của các dự đoán của chúng.

Như chúng ta có thể thấy trong **Hình 9.2**, trục x đại diện cho **tên của mô hình** mà chúng tôi đã sử dụng, và trục y đại diện cho **MSE tương ứng**. Các giá trị nằm trong khoảng từ **0.0 đến 3.0**, như được thấy trên trục y. Ở đây, **thanh càng thấp** cho mỗi mô hình, **hiệu suất của nó càng tốt**, vì lỗi càng thấp.



Hình 9.2 So sánh sai số trung bình bình phương.

- **Điểm R -squared (R^2 Score)**


Trong quá trình đánh giá mức độ hiệu quả của các mô hình ML phù hợp với dữ liệu năng suất cây trồng quan sát được, **điểm R -squared (R^2) đóng một vai trò quan trọng**. Chỉ số này định lượng **tỷ lệ phương sai tổng thể** trong dữ liệu năng suất cây trồng mà các mô hình có khả năng giải thích. Việc sử dụng điểm R^2 cho phép **đánh giá hiệu suất của các mô hình XGBoost, hồi quy đa thức và KNN** liên quan đến một mô hình tham chiếu.

Giá trị **0** cho R^2 (nằm trong khoảng từ 0 đến 1) cho thấy rằng, giống như một mô hình trung bình cơ bản, các mô hình **không thể giải thích bất kỳ biến thể nào trong năng suất cây trồng**. Ngược lại, **điểm R^2 là 1** báo hiệu rằng các mô hình có khả năng nắm

bắt tất cả sự biến động hiện diện trong dữ liệu, dẫn đến các dự đoán khớp chính xác với năng suất quan sát được.

Trong nghiên cứu này, **điểm R^2 cao hơn** chứng minh sự thành thạo của các mô hình **trong việc phân biệt các mô hình và xu hướng quan trọng** trong dữ liệu năng suất cây trồng. Những kết quả này nhấn mạnh **tầm quan trọng và độ tin cậy của các dự đoán của mô hình**, vì chúng cho thấy một **phần đáng kể của sự biến động năng suất được nắm bắt chính xác bởi các mô hình**.

Như chúng ta có thể thấy trong **Hình 9.3**, trục x đại diện cho **tên của mô hình** mà chúng tôi đã sử dụng, và trục y đại diện cho **điểm R-squared tương ứng**. Các giá trị nằm trong khoảng từ **0.0 đến 0.8**, như được thấy trên trục y. Ở đây, **thanh càng cao cho mỗi mô hình, hiệu suất của nó càng tốt**, vì điểm càng cao.



Hình 9.3 So sánh lỗi R -square.

9.5 KẾT LUẬN

ML đã trở thành một **công cụ hỗ trợ quyết định** thiết yếu để **dự báo năng suất cây trồng** trong nông nghiệp, cho phép **các quyết định sáng suốt** về lựa chọn và quản lý cây trồng trong suốt mùa sinh trưởng. Để ước tính năng suất cây trồng, nghiên cứu này đã sử dụng một **phân tích so sánh với ba mô hình ML: hồi quy tuyến tính, hồi quy đa thức và KNN**. Để cải thiện lĩnh vực nông nghiệp, điều cần thiết là **dự đoán năng suất cây trồng dựa trên các biến này**, bao gồm **hiệt độ, sử dụng thuốc trừ sâu, lượng mưa và điều kiện khí hậu**.

Bộ dữ liệu thu được đã trải qua quá trình **tiền xử lý rộng rãi** để loại bỏ dữ liệu dư thừa hoặc không chính xác trước khi đào tạo mô hình. Sau đó, bộ dữ liệu được **chia thành các tập hợp con đào tạo và thử nghiệm** để hiệu suất của mỗi mô hình có thể được đánh giá.

Chạy ba mô hình ML mà chúng tôi đã sử dụng, chúng tôi thấy rằng **KNN có cả MSE thấp nhất: $1.776102e + 08$ và điểm R^2 cao nhất: 0.948888**. Mặc dù hoạt động tốt trong các số liệu này, **KNN nên được sử dụng cẩn thận, vì nó có thể có xu hướng overfitting dữ liệu**, và nếu không, **XGBoost sẽ cung cấp một kết quả tương tự trong hầu hết các trường hợp**.

Các mô hình này có thể được sử dụng để **cải thiện hiệu quả của việc canh tác** bằng cách giúp cung cấp **việc sử dụng vật liệu và tài nguyên hiệu quả**. Nghiên cứu này nhấn mạnh cách ML có thể **cải thiện năng suất nông nghiệp và việc ra quyết định**, qua đó hỗ trợ **sự phát triển bền vững của ngành nông nghiệp**. Để **tối ưu hóa sản lượng cây trồng và thích ứng với các điều kiện môi trường thay đổi**, nông dân và các nhà hoạch định chính sách có thể sử dụng ML để làm lợi thế của họ. Điều này sẽ **đảm bảo an ninh lương thực và tăng trưởng kinh tế** trong lĩnh vực nông nghiệp.

TÀI LIỆU THAM KHẢO

1. “Economic Survey 2022–23: Agri growth rate falls but sector still resilient amid pandemic shock,” [www.downtoearth.org.in](https://www.downtoearth.org.in/news/agriculture/economic-survey-2022-23-agri-growth-rate-falls-but-sector-still-resilient-amid-pandemic-shock-87406). <https://www.downtoearth.org.in/news/agriculture/economic-survey-2022-23-agri-growth-rate-falls-but-sector-still-resilient-amid-pandemic-shock-87406>
2. N. Alex, C. C. Sobin, and J. Ali, “A comprehensive study on smart agriculture applications in India,” *Wireless Personal Communications*, vol. 129, no. 4, pp. 2345–2385, Mar. 2023. doi: 10.1007/s11277-023-10234-5
3. K. P. Kumar, A. Unal, V. J. Pillai, H. Murthy, and M. Niranjanamurthy, eds., *Data Engineering and Data Science: Concepts and Applications*. 2023. ISBN: 9781119841876.
4. A. Nigam, S. Garg, A. Agrawal, and P. Agrawal, “Crop yield prediction using machine learning algorithms,” *2019 Fifth International Conference on Image Information Processing (ICIIP)*, Shimla, India, 2019, pp. 125–130. doi: 10.1109/ICIIP47207.2019.8985951
5. K. P. Kumar, H. Murthy, V. J. Pillai, and B. R. Prathap, “Blockchain-enabled model for minimizing post harvest losses,” *ECS Transactions*, vol. 107, no. 1, p. 17475, 2022. doi: 10.1149/10701.17475ecst
6. I. A. Supro, “Rice yield prediction and optimization using association rules and neural network methods to enhance agribusiness,” *Indian Journal of Science and Technology*, vol. 13, no. 13, pp. 1367–1379, Apr. 2020. doi: 10.17485/ijst/v13i13.79
7. P. S. S. Gopi and M. Karthikeyan, “Red fox optimization with ensemble recurrent neural network for crop recommendation and yield prediction model,” *Multimedia Tools and Applications*, vol. 83, pp. 1–21, Jul. 2023.
8. S. Muthukumaran, P. Geetha, and E. Ramaraj, “Multi-objective optimization with artificial neural network based robust paddy yield prediction model,” *Intelligent Automation & Soft Computing*, vol. 35, no. 1, pp. 215–230, 2023. doi: 10.32604/iasc.2023.027449

9. K. Vignesh, A. Askarunisa, and A. M. Abirami, "Optimized deep learning methods for crop yield prediction," *Computer Systems Science and Engineering*, vol. 44, no. 2, pp. 1051–1067, 2023. doi: 10.32604/csse.2023.024475
10. M. Yoosefzadeh-Najafabadi, D. Tulpan, and M. Eskandari, "Application of machine learning and genetic optimization algorithms for modeling and optimizing soybean yield using its component traits," *PLOS ONE*, vol. 16, no. 4, p. e0250665, Apr. 2021. doi: 10.1371/journal.pone.0250665
11. G. Sunitha et al., "Modeling of chaotic political optimizer for crop yield prediction," *Intelligent Automation & Soft Computing*, vol. 34, no. 1, pp. 423–437, 2022. doi: 10.32604/iasc.2022.024757
12. H. Dokoochaki, T. Rai, M. Kivi, P. Lewis, J. Gómez-Dans, and F. Yin, "Linking remote sensing with APSIM through emulation and Bayesian optimization to improve yield prediction," *Remote Sensing*, vol. 14, no. 21, pp. 5389, Oct. 2022. doi: 10.3390/rs14215389
13. C. Chen, X. Wang, H. Chen, C. Wu, M. Mafarja, and H. Turabieh, "Towards precision fertilization: Multi-strategy grey wolf optimizer based model evaluation and yield estimation," *Electronics*, vol. 10, no. 18, p. 2183, Sep. 2021. doi: 10.3390/electronics10182183
14. U. Bhimavarapu, G. Battineni, and N. Chintalapudi, "Improved optimization algorithm in LSTM to predict crop yield," *Computers*, vol. 12, no. 1, p. 10, Jan. 2023. doi: 10.3390/computers12010010
15. K. P. Kumar, H. Murthy, V. J. Pillai, B. R. Prathap, M. Moses, and Y. Urs, "Data analysis and machine learning observation on production losses in the food processing industry," *2023 IEEE International Conference on Contemporary Computing and Communications (InC4)*, Bangalore, India, 2023, pp. 1–4. doi: 10.1109/InC457730.2023.10263147
16. R. Barzin, R. Pathak, H. Lotfi, J. J. Varco, and G. C. Bora, "Use of UAS multispectral imagery at different physiological stages for yield prediction and input resource optimization in corn," *Remote Sensing*, vol. 12, no. 15, pp. 2392, Jul. 2020. doi: 10.3390/rs12152392
17. P. S. Maya Gopal and R. Bhargavi, "Selection of important features for optimizing crop yield prediction," *International Journal of Agricultural and Environmental Information Systems*, vol. 10, no. 3, pp. 54–71, Jul. 2019. doi: 10.4018/ijaeis.2019070104
18. P. C. Roy, A. Guber, M. Abouali, A. P. Nejadhashemi, K. Deb, and A. J. M. Smucker, "Crop yield simulation optimization using precision irrigation and subsurface water retention technology," *Environmental Modelling & Software*, vol. 119, pp. 433–444, Sep. 2019. doi: 10.1016/j.envsoft.2019.07.006