

CHƯƠNG 12: PHÂN LOẠI CÁC TRANG TRẠI ĐỂ KHUYẾN NGHỊ TRỒNG LÚA SỬ DỤNG NAIVE BAYES VÀ SVM: MỘT NGHIÊN CỨU ĐIỂN HÌNH

Qurat-ul-ain, Uzma Hameed, và Hamira Mehraj Trường Cao đẳng Nữ, Đại học Cluster, Srinagar, Ấn Độ

12.1 GIỚI THIỆU

Dân số thế giới hiện tại khoảng 7,6 tỷ người, và ước tính sẽ đạt khoảng 9,8 tỷ người vào cuối năm 2050. Do đó, nhu cầu lương thực chắc chắn sẽ tăng lên, nhưng ngược lại, đất nông nghiệp đang giảm sút nghiêm trọng mỗi ngày do quản lý yếu kém trong canh tác, quy hoạch không hợp lý, điều kiện thời tiết không thể đoán trước, và quá trình đô thị hóa. Trong thời đại ngày nay, nông nghiệp chính xác đã trở nên vô cùng phổ biến trong ngành nông nghiệp với những kết quả lạc quan, và nó đã giúp ích rất nhiều trong các lĩnh vực khác nhau của nông nghiệp như tưới tiêu không đều, phát hiện bệnh cây trồng, đếm cây, khuyến nghị cây trồng, ước tính năng suất, thu hoạch chọn lọc, kiểm soát sâu bệnh, và phát hiện cỏ dại, cũng như nhiều lĩnh vực khác của nông nghiệp.

Nông nghiệp chính xác là một chiến lược quản lý thu thập, xử lý và phân tích dữ liệu thời gian, không gian và cá nhân, đồng thời kết hợp nó với thông tin khác để hỗ trợ các quyết định quản lý theo sự biến đổi ước tính nhằm cải thiện hiệu quả sử dụng tài nguyên, năng suất, chất lượng, lợi nhuận và tính bền vững của sản xuất nông nghiệp. Để hiểu rõ hơn về dữ liệu được truy xuất từ nông nghiệp chính xác, các kỹ thuật học máy (ML) rất được khuyến khích và sử dụng trong lĩnh vực này. Với việc triển khai các công cụ ML, chúng ta có thể tối ưu hóa quy trình và giảm sai sót trong dữ liệu, các dự đoán trở nên dễ dàng hơn, và việc diễn giải dữ liệu hình ảnh trở nên nhanh chóng và đơn giản. “Học máy là một nhánh của khoa học máy tính, nói rộng ra là nhằm mục đích cho phép máy tính ‘học’ mà không cần được lập trình trực tiếp”.

“Một cỗ máy hoặc một chương trình máy tính thông minh học và trích xuất kiến thức từ dữ liệu; kiến thức được trích xuất sau đó xây dựng một khuôn khổ giúp đưa ra các dự đoán hoặc quyết định thông minh. Do đó, quy trình ML được chia thành ba phần chính - tức là, nhập dữ liệu, xây dựng mô hình, và tổng quát hóa”. “Tổng quát hóa là quá trình dự đoán đầu ra cho các đầu vào mà thuật toán chưa được huấn luyện trước đó”. Các thuật toán ML có thể được sử dụng để xây dựng mô hình phân loại nhằm phát hiện chất lượng đất để canh tác cây trồng phù hợp. Trong chương này, chúng ta sẽ tìm hiểu một chủ đề tương tự như một nghiên cứu điển hình. Để triển khai một mô hình dự đoán, chúng ta hãy lấy một tập dữ liệu gồm 2.200 mẫu và sửa đổi nó theo việc trồng lúa và triển khai hai mô hình dự đoán ML - tức là, Naive Bayes và máy vector hỗ trợ (SVM) để dự đoán trang trại trồng lúa. Chúng ta cũng sẽ thực hiện một nghiên cứu so sánh hai mô hình này dựa trên các thước đo độ chính xác khác nhau.

12.2 TỔNG QUAN TÀI LIỆU

Lúa, như chúng ta đã biết, là một trong những cây trồng được tiêu thụ nhiều nhất trên toàn cầu. Nông dân phải đối mặt với rất nhiều khó khăn khi đưa ra quyết định để đạt được năng suất và cây trồng bền vững trong điều kiện khí hậu thay đổi. “Các kỹ thuật Học máy có thể được sử dụng để cải thiện dự đoán năng suất cây trồng dưới các điều kiện khí hậu khác nhau”. Một số lượng lớn các nhà nghiên cứu đã áp dụng các thuật toán ML để phát hiện bệnh lúa. Jian và Wei đã áp dụng SVM để nhận dạng bệnh trên lá dừa chuột. Kết quả của họ đã cho thấy phương pháp SVM dựa trên hàm nhân (kernel) radial basis function (RBF) cho hiệu suất tốt nhất để phân loại bệnh của dừa chuột so với các hàm nhân đa thức và sigmoid. Sethy, Barpanda, Rath, và Behera đã làm việc về phát hiện bệnh lá lúa dựa trên đặc trưng sâu (deep feature) bằng CNN và SVM.

Gandhi, Petkar, và Armstrong đã sử dụng mạng nơ-ron để dự đoán năng suất sản xuất lúa và để điều tra các yếu tố ảnh hưởng đến “năng suất lúa cho các quận khác nhau của bang Maharashtra ở Ấn Độ”. Các thông số được các nhà nghiên cứu này xem xét khi thực hiện nghiên cứu của họ là “lượng mưa, nhiệt độ tối thiểu, nhiệt độ trung bình, nhiệt độ tối đa và lượng bốc hơi nước tham chiếu của cây trồng (reference crop evapotranspiration), diện tích, sản lượng và năng suất cho vụ Kharif (tháng 6 đến tháng 11) trong các năm từ 1998 đến 2002.” Singha và cộng sự đã sử dụng “kỹ thuật trí tuệ nhân tạo (AI) cho mô hình dự đoán năng suất lúa và khoai tây ở khu vực Tarakeswar, Quận Hooghly, Tây Bengal.” Các biến được sử dụng chủ yếu trong nghiên cứu là “các yếu tố khí hậu, các thông số đất tĩnh, dinh dưỡng có sẵn trong đất, các thông số thực hành nông nghiệp, cơ giới hóa nông nghiệp, phân bố địa hình và các điều kiện kinh tế-xã hội.” Họ đã sử dụng “mạng nơ-ron nhân tạo, Máy vector hỗ trợ và Mạng nơ-ron sâu” trong nghiên cứu của mình.

Nghiên cứu của Hasan và cộng sự đã giới thiệu một kiến trúc CNN mới có kích thước tương đối nhỏ và hiệu suất khá hứa hẹn để dự đoán bệnh lá lúa với độ chính xác vừa phải và độ phức tạp thời gian thấp hơn. Patil và Kumar đã đề xuất một khung hợp nhất dữ liệu đa phương thức (multimodality data fusion framework) để phát hiện bệnh lúa.

Khung Rice-Fusion ban đầu trích xuất các đặc trưng số từ dữ liệu khí tượng nông nghiệp (agro-meteorological) thu thập từ các cảm biến. Tiếp theo, nó trích xuất các đặc trưng trực quan từ hình ảnh lúa được chụp. Các đặc trưng được trích xuất này sau đó được hợp nhất bằng cách sử dụng một lớp ghép nối (concatenation layer) theo sau là một lớp dày đặc (dense layer), cung cấp đầu ra duy nhất để chẩn đoán bệnh lúa.

Kumar, Singh, Kumar, và P. Singh đã đề xuất một phương pháp có tên là Phương pháp Chọn Cây trồng (CSM) để giải quyết vấn đề lựa chọn cây trồng và tối đa hóa tỷ lệ năng suất ròng của cây trồng qua một mùa vụ và sau đó đạt được tăng trưởng kinh tế tối đa cho đất nước. Son và cộng sự đã phát triển một phương pháp ML để dự đoán năng suất lúa ở Đài Loan bằng cách sử dụng dữ liệu Chuỗi thời gian của Máy đo phổ hình ảnh độ phân giải trung bình (MODIS). Rừng ngẫu nhiên (RF) và SVM đã được sử dụng để xây dựng các mô hình dự đoán.

12.3 PHƯƠNG PHÁP LUẬN

Tập dữ liệu được sử dụng cho nghiên cứu đã được xử lý bằng công cụ WEKA. “WEKA (Môi trường Waikato để Phân tích Kiến trúc) , là công cụ khai thác dữ liệu mã nguồn mở và miễn phí, có sẵn theo Giấy phép Công cộng GNU.” Công cụ này được phát triển tại Đại học Waikato, New Zealand, và được triển khai lần đầu tiên ở dạng hiện đại vào năm 1997. Ngoài định dạng tệp dữ liệu arff, công cụ WEKA cũng hỗ trợ định dạng tệp dữ liệu .csv, giúp thuận tiện cho việc xuất dữ liệu sang các ứng dụng bảng tính khác nhau. Chúng tôi đã sử dụng WEKA phiên bản 3.8.6 để thực hiện các thí nghiệm cho mục đích giải thích.


Tập dữ liệu đã được sử dụng làm đầu vào cho các bộ phân loại có sẵn trên kho lưu trữ Kaggle. Tên của tập dữ liệu này là tập dữ liệu “khuyến nghị cây trồng”. Đây là một tập dữ liệu đa biến với 2.200 mẫu và kích thước của nó là 65 KB. Tổng số thuộc tính trong tập dữ liệu này là tám, bao gồm cả thuộc tính nhãn mục tiêu. Tập dữ liệu này được phân loại cho các loại cây trồng khác nhau, nhưng chúng tôi đã chuyển đổi thuộc tính nhãn của tập dữ liệu thành có/không (yes/no) theo các khuyến nghị trồng lúa. Các thuộc tính được chọn của tập dữ liệu đang nghiên cứu được định nghĩa trong Bảng 12.1.

BẢNG 12.1: Mô tả các Thuộc tính

STT.	Thuộc tính được sử dụng trong Tập dữ liệu	Loại thuộc tính	Mô tả
1	N	Số	Tỷ lệ hàm lượng nitơ trong đất
2	P	Số	Tỷ lệ hàm lượng photpho trong đất
3	K	Số	Tỷ lệ hàm lượng kali trong đất
4	Temperature	Số	Nhiệt độ tính bằng độ C
5	Humidity	Số	Độ ẩm tương đối tính bằng phần trăm
6	Ph	Số	Giá trị Ph của đất
7	Rainfall	Số	Lượng mưa tính bằng mm
8	Label	Chuỗi	Có/Không

12.3.1 Quy trình làm việc

Tập dữ liệu đầu vào được xử lý bằng hai bộ phân loại ML - Naive Bayes và SVM. Các bộ phân loại này được huấn luyện và kiểm tra độ chính xác bằng cùng một tập dữ liệu. Dựa trên các kết quả thí nghiệm thu thập được, thuật toán hoạt động tốt nhất sẽ được xác định, giúp dự đoán cây lúa để trồng trên một trang trại cụ thể dựa trên các thông số được mô tả trong Hình 12.1.



HÌNH 12.1 Lưu đồ của phương pháp đề xuất. “Raw dataset” flows to “Rice Prediction Dataset”. This splits into “Test Set” and “Training Set”. The “Training Set” flows to both “SVM” and “Naive Bayes Algorithm”. Both “SVM” and “Naive Bayes Algorithm” flow to “Classifier Models”. The “Test Set” also flows to “Classifier Models”. Finally, “Classifier Models” flows to “RESULTS OF THE STUDY”.]

12.3.2 Thủ tục

Quy trình sau đây đã được tuân thủ khi xây dựng các bộ phân loại và tính toán độ chính xác của các thuật toán bằng công cụ WEKA.

1. Công cụ chọn WEKA GUI cho phép linh hoạt lựa chọn giữa Simple CLI, Knowledge Explorer, Experimenter, và Explorer CUI. Thí nghiệm được thực hiện bằng giao diện WEKA Explorer.
2. Tải tập dữ liệu đầu vào về khuyến nghị trồng lúa trong công cụ WEKA.
3. Chọn thuật toán ML là Naive Bayes hoặc SVM Tối ưu hóa Tối thiểu Tuần tự (SMO).
4. Kiểm tra chéo (Cross-validation) đã được chọn làm tùy chọn kiểm tra, được đặt mặc định là 10 lần (ten folds).
5. Kiểm tra mô hình phân loại cho thuật toán đã chọn.
6. Thực hiện so sánh các kết quả thu được từ các thuật toán.

12.4 GIẢI THÍCH VỀ CÁC BỘ PHÂN LOẠI

12.4.1 Naive Bayes

Naive Bayes là một bộ phân loại học có giám sát hoạt động dựa trên nguyên tắc xác suất có điều kiện. Với nhiều đầu vào $(x_1, x_2, x_3, x_4 \dots x_n)$, lớp kết quả (Y) sử dụng phương trình Naive Bayes có thể được tính là:

$$P(Y = K | X_1 \dots X_n) = \frac{\left(P(X_1 | Y = K) * P(X_2 | Y = K) * P(X_3 | Y = K) * \dots * P(X_n | Y = K) * P(Y = K) \right)}{\left(P(X_1) * P(X_2) * P(X_3) \dots P(X_n) \right)}. \quad (12.1)$$

Trong tập dữ liệu đang nghiên cứu, bộ phân loại Naive Bayes (12.1) được áp dụng cho các thuộc tính sau:

$X = (N, P, K, \text{Temperature, Humidity, Ph, rainfall})$ và lớp kết quả Y được phân loại là $Y = (\text{Yes, No})$.

Có nhiều loại ma trận đánh giá khác nhau trong ML (ví dụ: “Độ chính xác Phân loại, Mật mát Logarit, Ma trận Nhầm lẫn, Diện tích dưới Đường cong, Điểm F1, Lỗi Tuyệt đối Trung bình, và Lỗi Bình phương Trung bình”). Trong nghiên cứu điển hình này, chúng tôi đã xem xét các thước đo đánh giá Ma trận Nhầm lẫn, Độ chính xác Phân loại, và Diện tích dưới Đường cong (AUC) để thực hiện phân tích so sánh các thuật toán.

12.4.1.1 Ma trận Nhầm lẫn Naive Bayes

Bảng 12.2 cho thấy Ma trận Nhầm lẫn thu được bằng cách sử dụng bộ phân loại Naive Bayes.

Do đó, theo bộ phân loại này, các giá trị là **Dương tính Thật = 100**, **Âm tính Sai = 0**, **Dương tính Sai = 43**, và **Âm tính Thật = 2057**.

BẢNG 12.2: Ma trận Nhầm lẫn Thu được bằng cách sử dụng Naive Bayes

		Lớp Dự đoán	
Lớp Thực tế		Dương tính	Âm tính
	Dương tính	100	0
	Âm tính	43	2057

12.4.2 Máy Vector Hỗ trợ (Support Vector Machines - SVM)

SVM là một thuật toán học có giám sát, thường được sử dụng cho các bài toán dựa trên phân loại và hồi quy. Khái niệm chính của SVM, ban đầu được phát triển để giải quyết các vấn đề liên quan đến phân loại nhị phân, là sử dụng các siêu phẳng (hyperplanes) để

xác định ranh giới quyết định giữa các điểm dữ liệu thuộc các lớp khác nhau. SVM có thể xử lý cả các tác vụ phân loại đơn giản và tuyến tính, đồng thời cũng có thể giúp xử lý các bài toán phân loại phức tạp hơn - tức là, phi tuyến. Cả hai bài toán có thể phân tách (separable) và không thể phân tách (nonseparable) đều có thể được xử lý tốt bởi SVM trong các trường hợp tuyến tính và phi tuyến. Ý tưởng đằng sau SVM là ánh xạ các điểm dữ liệu gốc từ không gian đầu vào sang một không gian đặc trưng có số chiều cao, hoặc thậm chí vô hạn, sao cho bài toán phân loại trở nên đơn giản hơn trong không gian đặc trưng. Việc ánh xạ được thực hiện bằng một lựa chọn phù hợp của hàm nhân (kernel function). Trong WEKA, chúng tôi đã sử dụng thuật toán SMO để huấn luyện một bộ phân loại vector hỗ trợ bằng cách sử dụng nhân tuyến tính (linear kernel) trên tập dữ liệu đã cho để xây dựng mô hình phân loại.

$K(x, y) = \langle x, y \rangle$ và bộ phân loại cho lớp Đúng, Sai

12.4.2.1 Ma trận Nhầm lẫn Vector Hỗ trợ

Bảng 12.3 cho thấy Ma trận Nhầm lẫn thu được bằng cách sử dụng bộ phân loại vector hỗ trợ. Do đó, theo bộ phân loại này, các giá trị là **Dương tính Thật = 64**, **Âm tính Sai = 36**, **Dương tính Sai = 3**, và **Âm tính Thật = 2097**

BẢNG 12.3: Ma trận Nhầm lẫn Thu được bằng cách sử dụng SVM

		Lớp Dự đoán	
Lớp Thực tế		Dương tính	Âm tính
	Dương tính	64	36
	Âm tính	3	2097

BẢNG 12.4: Kết quả Độ chính xác cho các Bộ phân loại

Thuật toán	Thời gian Xây dựng Mô hình (giây)	Giá trị Độ chính xác (%)
Naive Bayes	0.01	98.0455
SVM sử dụng công cụ WEKA	0.11	98.2273


12.5 ĐỘ CHÍNH XÁC (ACCURACY)

Độ chính xác (Accuracy) là một ma trận đánh giá hiệu suất khác cho các mô hình phân loại (Bảng 12.4). Nó được tính bằng tổng số mẫu được dự đoán đúng chia cho tổng số mẫu có trong tập dữ liệu.

$$\text{Độ chính xác} = (TP + TN) / (TP + TN + FP + FN), (12.2)$$

trong đó ở (12.2) TP = Dương tính Thật, TN = Âm tính Thật, FP = Dương tính Sai, FN = Âm tính Sai.

Hình 12.2 mô tả đồ họa các kết quả độ chính xác cho các bộ phân loại, trong đó hiển thị thời gian xây dựng mô hình và các giá trị độ chính xác.



HÌNH 12.2 Biểu diễn đồ họa của kết quả độ chính xác. The Naive Bayes bar shows “0.01 sec, 98.05%”. The Support Vector Machine bar is higher, showing “0.11 sec, 98.23%”. The Y-axis represents “Accuracy Value” ranging from 97.95% to 98.25%.]

12.6 DIỆN TÍCH DƯỚI ĐƯỜNG CONG (AREA UNDER CURVE - AUC)

AUC (Diện tích dưới Đường cong) là một cách khác để đo lường hiệu suất của mô hình ML. AUC càng cao, hiệu suất của mô hình trong việc phân biệt giữa các lớp dương tính và âm tính càng tốt. Sau đây là các giá trị đo lường độ chính xác của bộ phân loại:

I. Tỷ lệ Dương tính Thật (True-Positive Rate): Nó mô tả phần nào của lớp dương tính được phân loại chính xác. Nó được tính là:

$$\text{TruePositive - Rate} = \frac{\text{TruePositive}}{(\text{TruePositive} + \text{FalseNegative})} \quad (12.3)$$

II. Tỷ lệ Dương tính Sai (False-Positive Rate): Nó mô tả phần nào của dữ liệu được phân loại là bất thường, mà thực sự là bình thường.

$$\text{FalsePositive - Rate} = \frac{\text{FalsePositive}}{(\text{FalsePositive} + \text{TrueNegative})} \quad (12.4)$$

III. Độ chuẩn xác (Precision): Nó mô tả số lượng dự đoán dương tính chính xác được thực hiện. Nó được tính là:

$$\text{Precision} = \frac{\text{TruePositive}}{(\text{TruePositive} + \text{FalsePositive})} \quad (12.5)$$

IV. Độ phủ (Recall): Nó mô tả số lượng dự đoán dương tính chính xác được thực hiện trong tất cả các dự đoán dương tính có thể đã được thực hiện. Nó được tính là:

$$\text{Recall} = \frac{\text{TruePositive}}{(\text{TruePositive} + \text{FalseNegative})} \quad (12.6)$$

V. Chỉ số F (F-Measure): Nó mô tả hiệu suất tổng thể của bộ phân loại. Nó được tính là:

$$\text{F-Measure} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall}). \quad (12.7)$$

BẢNG 12.5: Các chỉ số AUC của các Thuật toán

Thuật toán	Tỷ lệ TP	Tỷ lệ FP	Độ chuẩn xác	Độ phủ	Chỉ số F
Naive Bayes	0.980	0.001	0.986	0.980	0.982
SVM	0.982	0.344	0.982	0.982	0.981

Bảng 12.5 trình bày các chỉ số AUC (12.3)-(12.7) của các thuật toán này thu được sau khi xây dựng các bộ phân loại trên tập dữ liệu trong công cụ WEKA.

12.7 KẾT LUẬN

Trong chương này, một mô hình dự đoán dựa trên các bộ phân loại Naive Bayes và SVM đã được sử dụng để dự đoán liệu một trang trại cụ thể có thể được khuyến nghị để trồng lúa hay không. Tập dữ liệu được sử dụng để thực hiện nghiên cứu dự đoán các trang trại được lấy từ kho lưu trữ Kaggle, chứa các thuộc tính khác nhau về đất và hành vi môi trường. Các bộ phân loại Naive Bayes và SVM đã được xây dựng bằng công cụ WEKA. Do đó, các bộ phân loại này đã được so sánh dựa trên các thước đo độ chính xác khác nhau để kiểm tra hiệu suất bằng cách sử dụng cùng một tập dữ liệu trên hai mô hình khác nhau. Nghiên cứu đã dẫn đến kết luận rằng Tỷ lệ TP (TP Ratify Rate) và Độ phủ (Recall) của SVM cao hơn so với Naive Bayes. Tuy nhiên, độ chuẩn xác (precision) và chỉ số F (F-measure) của Naive Bayes cao hơn so với SVM. Giá trị độ chính xác của SVM là 98.2273%, cao hơn một chút so với bộ phân loại Naive Bayes. Tuy nhiên, thời gian xây dựng mô hình trong Naive Bayes là 0.01 giây, ít hơn so với thời gian sử dụng SVM. Vì chúng ta nên quan tâm chủ yếu đến độ chính xác của mô hình hơn là thời gian xây dựng mô hình, SVM là lựa chọn tốt nhất được thiết lập bởi nghiên cứu so sánh hiện tại. Trong tương lai, chúng ta có thể so sánh các mô hình dự đoán khác như hồi quy logistic, cây quyết định hỗ trợ, rừng ngẫu nhiên, và mạng nơ-ron với SVM để thiết lập các mô hình dự đoán tốt hơn cho tập dữ liệu hiện tại. Hơn nữa, bộ thuộc tính cũng có thể được tăng cường dựa trên các yếu tố môi trường khác nhau để thiết lập kết quả chính xác hơn, để chúng ta có thể chọn đúng trang trại để trồng lúa.

TÀI LIỆU THAM KHẢO

- [1] A. Sharma, A. Jain, P. Gupta, và V. Chowdary, “Ứng dụng Học máy cho Nông nghiệp Chính xác: Một Đánh giá Toàn diện,” IEEE Access, tập 9, trang 4843-4873, tháng 1 năm 2021. doi: 10.1109/access.2020.3048415
- [2] Hiệp hội Nông nghiệp Chính xác Quốc tế, “Định nghĩa Nông nghiệp Chính xác (Precision AG) Hiệp hội Nông nghiệp Chính xác Quốc tế.” <https://www.ispag.org/about/definition>
- [3] A. L. Samuel, “Một số Nghiên cứu về Học máy Sử dụng Trò chơi Cờ đam,” Tạp chí Nghiên cứu và Phát triển của IBM, tập 3, số 3, trang 210-229, tháng 7 năm 1959. doi: 10.1147/rd.33.0210
- [4] N. Gandhi, L. J. Armstrong, O. Petkar, và A. K. Tripathy, “Dự đoán Năng suất Lúa ở Ấn Độ Sử dụng Máy Vector Hỗ trợ,” trong 2016 13th International Joint Conference on Computer Science and Software Engineering (JCSSE), KhonKaen, Thái Lan, 2016, trang 1-5. doi:10.1109/JCSSE.2016.7748856
- [5] Z. Jian và Z. Wei, “Máy Vector Hỗ trợ để Nhận dạng Bệnh lá Dưa chuột,” trong 2010 2nd International Conference on Advanced Computer Control, Thẩm Dương, 2010, trang 264-266. doi: 10.1109/ICACC.2010.5487242
- [6] P. K. Sethy, N. K. Barpanda, A. K. Rath, và S. K. Behera, “Nhận dạng Bệnh lá Lúa dựa trên Đặc trưng Sâu Sử dụng Máy Vector Hỗ trợ,” Computers and Electronics in Agriculture, tập 175, trang 105527, tháng 8 năm 2020. doi: 10.1016/j.compag.2020.105527
- [7] N. Gandhi, O. Petkar, và L. Armstrong, “Dự đoán Năng suất Lúa Sử dụng Mạng Nơ-ron Nhân tạo,” trong 2016 IEEE Technological Innovations in ICT for Agriculture and Rural Development (TIAR), Chennai, Ấn Độ, 2016, trang 105-110. doi: 10.1109/tiar.2016.7801222
- [8] C. Singha và K. C. Swain, “Dự đoán Năng suất Lúa và Khoai tây Sử dụng Kỹ thuật Trí tuệ Nhân tạo,” trong Studies in Big Data, 2021, trang 185-199. doi: 10.1007/978-981-16-6210-2_9
- [9] M. M. Hasan và cộng sự, “Nâng cao Quản lý Cây lúa: Phân loại Bệnh bằng Mạng Nơ-ron Tích chập và Tích hợp Ứng dụng Di động,” Agriculture, tập 13, số 8, trang 1549, tháng 8 năm 2023. doi: 10.3390/agriculture13081549
- [10] R. R. Patil và S. Kumar, “Rice-Fusion: Một Khung Hợp nhất Dữ liệu Đa phương thức để Chẩn đoán Bệnh lúa,” IEEE Access, tập 10, trang 5207-5222, tháng 1 năm 2022. doi: 10.1109/access.2022.3140815
- [11] R. Kumar, M. P. Singh, P. Kumar và J. P. Singh, “Phương pháp Lựa chọn Cây trồng để Tối đa hóa Tỷ lệ Năng suất Cây trồng Sử dụng Kỹ thuật Học máy,” trong 2015

International Conference on Smart Technologies and Management for Computing, Communication, Controls, Energy and Materials (ICSTM), Avadi, Ấn Độ, 2015, trang 138-145. doi: 10.1109/ICSTM.2015.7225403

[12] N. T. Son và cộng sự, “Các Phương pháp Học máy để Dự đoán Năng suất Lúa Sử dụng Dữ liệu Vệ tinh Chuỗi thời gian ở Đài Loan,” International Journal of Remote Sensing, tập 41, số 20, trang 7868-7888, tháng 8 năm 2020. doi: 10.1080/01431161.2020.1766148

[13] “Weka 3 Data Mining with Open Source Machine Learning Software in Java.” <https://www.cs.waikato.ac.nz/ml/weka/index.html>

[14] J. Luts, F. Ojeda, R. Van De Plas, B. De Moor, S. Van Huffel, và J.A.K. Suykens, “Hướng dẫn về các Phương pháp dựa trên Máy Vector Hỗ trợ cho các Bài toán Phân loại trong Đo lường Hóa học (Chemometrics),” Analytica Chimica Acta, tập 665, số 2, trang 129-145, tháng 4 năm 2010. doi: 10.1016/j.aca.2010.03.030