

CHƯƠNG 3: HỌC MÁY (MACHINE LEARNING)

Như chúng ta đã biết, có nhiều nhánh khác nhau của trí tuệ nhân tạo và học máy là một trong số đó, đã trở thành một nhánh tiên tiến và được sử dụng rộng rãi nhất của trí tuệ nhân tạo trong mọi lĩnh vực của thế hệ này, có thể là điện tử, xây dựng, cơ khí, kỹ thuật sinh học, y tế hoặc nông nghiệp, v.v.. Trong chương này, chúng ta sẽ nghiên cứu về học máy và các loại của nó cùng với các thuật toán học máy phổ biến nhất đang được sử dụng chủ yếu trong các tình huống khác nhau và việc triển khai chúng bằng ngôn ngữ python đã được thảo luận trong phần triển khai của cuốn sách này. Ở đây, chúng ta cũng sẽ xem học máy có thể được sử dụng ở đâu.

I. Giới thiệu


Học máy là một tập hợp con của Trí tuệ Nhân tạo và là một trong những phần quan trọng nhất của Trí tuệ Nhân tạo. Đây là một lĩnh vực của khoa học máy tính hoàn toàn khác biệt so với các phương pháp tính toán truyền thống. Trong các phương pháp truyền thống, một tập hợp các chỉ dẫn được cung cấp rõ ràng cho thuật toán để giải quyết bất kỳ vấn đề nào. Trong khi đó, Học máy là một lĩnh vực của AI, sử dụng phân tích thống kê và có thể cho phép một hệ thống luôn học hỏi từ dữ liệu của nó mà không cần bất kỳ đầu vào bên ngoài nào để đưa ra một kết quả đầu ra thiết yếu. Nhờ đó, học máy giúp máy tính tiến bộ hơn trong việc tạo ra mô hình cung cấp quyết định dựa trên dữ liệu đầu vào.

Học máy bao gồm rất nhiều thuật toán, thường dựa trên các yêu cầu và chức năng của chúng để sử dụng ở đâu và khi nào. Để tạo một mô hình học máy, chúng ta luôn cần dữ liệu để mô hình có thể được xây dựng dựa trên đó. Học máy sử dụng thuật toán liên tục học hỏi từ dữ liệu có sẵn dưới dạng dữ liệu huấn luyện. Một mô hình học máy được tạo ra sau khi thuật toán được huấn luyện từ dữ liệu. Sau khi quá trình huấn luyện hoàn tất, khi mô hình đã được huấn luyện được cung cấp dữ liệu thực tế khác, bạn có thể nhận được một kết quả thiết yếu. Ví dụ, trong hình 3.1 Mô hình Học máy, chúng ta sử dụng một thuật toán dự đoán và tạo ra một mô hình bằng cách cung cấp cho nó một số dữ liệu, và sau đó chúng ta có thể nhận được các dự đoán dựa trên dữ liệu thực tế làm đầu vào.

Trong bất kỳ lĩnh vực nào, người dùng công nghệ luôn được hưởng lợi từ Học máy. Trong trí tuệ nhân tạo, vì Học máy luôn là lĩnh vực liên tục phát triển, và thêm vào đó, luôn có những cân nhắc phải ghi nhớ khi học các thuật toán học máy và các phương pháp luận của chúng hoặc phân tích của chúng trong các lĩnh vực khác nhau.

HỌC LẬP TỪ DỮ LIỆU (ITERATIVE LEARNING FROM DATA): Vì các mô hình học máy luôn được huấn luyện từ các bộ dữ liệu khác nhau trước khi được triển khai để sử dụng. Một số mô hình trực tuyến (online) và có thể thích ứng liên tục với dữ liệu mới. Mặt khác, một số mô hình học máy ngoại tuyến (offline) được huấn luyện và một khi được triển khai ở đâu đó thì không thể thay đổi và chúng luôn đưa ra kết quả dựa trên (dữ liệu huấn luyện) đó. Các mô hình trực tuyến trong học máy thực hiện học lặp (iterative learning) vì chúng liên tục nhận được dữ liệu mới, trong đó các thuật toán tạo ra các mẫu (patterns) và liên kết nó với các yếu tố dữ liệu có trong dữ liệu. Sau khi một mô hình

được huấn luyện, nó có thể được sử dụng trong thời gian thực để học từ dữ liệu và cho chúng ta những kết quả ý nghĩa.



Hình 3.1 Mô hình Học máy

II. Phương pháp tiếp cận Học máy

Khi chúng ta nói về một số loại vấn đề được giải quyết bằng học máy, chúng liên quan đến các loại thuật toán khác nhau. Tương tự như vậy, chúng ta có các kỹ thuật khác nhau trong học máy có thể được sử dụng trong các tình huống khác nhau. Đối với các phát biểu vấn đề khác nhau, chúng ta sử dụng các kỹ thuật học máy khác nhau, có thể dựa trên loại và khối lượng dữ liệu. Học máy có các danh mục khác nhau được thảo luận ở đây:

1. Học có giám sát (Supervised Learning)

Đây là (phương pháp) Học máy được sử dụng phổ biến và rộng rãi nhất. Việc xây dựng mô hình luôn phụ thuộc vào dữ liệu có sẵn và loại đầu ra mà chúng ta yêu cầu. Trong học có giám sát, các mô hình được cung cấp dữ liệu đã được phân loại và gán nhãn sẵn cho mục đích huấn luyện hoặc để học, và sau đó bằng cách tính toán mô hình với dữ liệu thực tế khác, các kết quả được so sánh với các kết quả đã được huấn luyện giả định hoặc mong đợi. Nếu tìm thấy sự không khớp hoặc lỗi nhất định, mô hình sẽ được huấn luyện lại với nhiều dữ liệu hơn. Vì học có giám sát luôn được sử dụng để dự đoán dựa trên các mẫu được tìm thấy trong dữ liệu hoặc trên dữ liệu chưa được gán nhãn được cung cấp cho mô hình. Nói cách khác, học có giám sát có thể được cho là học có hướng dẫn hoặc học có “thầy”, nơi chúng ta có một bộ dữ liệu đã được gán nhãn sẵn, hoạt động như một giáo viên để mô hình Học máy học hỏi. Nếu mô hình được huấn luyện, nó sẽ bắt đầu dự đoán hoặc xác định nếu dữ liệu mới được đưa vào.

Các chi tiết có thể được hiểu là: Giả sử chúng ta có các biến đầu vào, x và biến đầu ra, y , để tìm hiểu cách hàm ánh xạ (mapping function) có thể được học từ đầu vào đến đầu ra, chẳng hạn như: $Y = f(x)$

Bây giờ, mục tiêu chính là xấp xỉ hàm ánh xạ sao cho biến đầu ra (Y) có thể được dự đoán cho dữ liệu đó nếu chúng ta có đầu vào mới (x).

Hai loại vấn đề có thể được phân loại chủ yếu vào Học có giám sát:

- **Phân loại (Classification):** Một truy vấn phân loại được đặt tên khi chúng ta có hiệu suất được phân loại (categorized performance) như “đen”, “dạy học”, “không dạy học”, v.v.
- **Hồi quy (Regression):** Một vấn đề hồi quy được đặt tên nếu có giá trị đầu ra thực, như “chiều rộng”, “kilogram”, v.v.

Các ví dụ về thuật toán học máy có giám sát là cây quyết định (decision tree), rừng ngẫu nhiên (random forest), knn, hồi quy logistic (logistic regression).

Một ứng dụng phổ biến của học có giám sát là sử dụng dữ liệu lịch sử để dự đoán thống kê các sự kiện trong tương lai. Bạn có thể dự báo các biến động sắp tới bằng cách sử dụng kiến thức thị trường chứng khoán lịch sử hoặc sử dụng (bộ lọc) thư rác để lọc (thư). Hình ảnh cây trồng hoặc cây lương thực được gắn thẻ (tagged) trong nông nghiệp có thể được sử dụng làm dữ liệu đầu vào trong huấn luyện có giám sát để phân loại các hình ảnh cây trồng và cây lương thực chưa được gắn thẻ.

2. Học không giám sát (Unsupervised Learning)

Học không giám sát là tốt nhất nếu câu hỏi liên quan đến một lượng lớn dữ liệu không được gán nhãn. Việc biết ý nghĩa đằng sau dữ liệu này bao gồm các thuật toán có thể được hiểu bằng cách phân loại dữ liệu trên cơ sở các mẫu hoặc cụm (clusters) được tìm thấy. Do đó, học không giám sát thực hiện một quy trình xử lý dữ liệu lặp đi lặp lại mà không có sự can thiệp của con người.

Các thuật toán trong học không giám sát phân đoạn dữ liệu thành các nhóm (cụm) nổi bật hoặc các nhóm đặc trưng. Dữ liệu không được gán nhãn xác định các giá trị của tham số và việc phân loại dữ liệu. Phương pháp này về cơ bản áp dụng các nhãn cho thông tin để nó trở thành có giám sát và mô hình được huấn luyện. Học không giám sát sẽ (hữu ích) khi có một lượng lớn dữ liệu. Nhà phát triển không biết bối cảnh của dữ liệu để phân tích trong trường hợp này, vì vậy tại thời điểm này, việc dán nhãn là không thể. Đó là lý do tại sao học không giám sát do đó có thể được sử dụng như bước đầu tiên trước khi dữ liệu được chuyển sang một quy trình học có kiểm soát (supervised).

Các chi tiết có thể được hiểu là: Giả sử chúng ta có một biến đầu vào x , và không có biến đầu ra nào có sẵn như trong các thuật toán học có giám sát. Nói một cách đơn giản, chúng ta có thể kết luận rằng không có câu trả lời đúng và không có người hướng dẫn

trong học không giám sát. Các thuật toán cho phép người dùng xác định các xu hướng dữ liệu hấp dẫn.

Hai dạng vấn đề sau đây có thể được chia thành các vấn đề học không giám sát:

- **Phân cụm (Clustering):** Chúng ta phải khám phá các nhóm (groupings) cơ bản của dữ liệu trong các vấn đề phân cụm. Ví dụ, phân nhóm người tiêu dùng theo hành vi mua sắm.
- **Kết hợp (Association):** Một vấn đề kết hợp được đặt tên như vậy vì những vấn đề này yêu cầu các quy tắc phải được khám phá để giải thích nhiều dữ liệu của chúng ta, ví dụ, để tìm những khách hàng mua cả x và y .

Các thuật toán học không giám sát có thể giúp hiểu được một lượng lớn nội dung mới, chưa được gán nhãn. Các thuật toán này tìm kiếm các mẫu dữ liệu tương tự như (học) có giám sát. khác biệt là dữ liệu không được biết trước. Ví dụ, Các thuật toán học máy Không giám sát là K-means để phân cụm, thuật toán Apriori để kết hợp.

Trong lĩnh vực nông nghiệp, việc thu thập một lượng lớn dữ liệu về một lĩnh vực cụ thể, ví dụ, sẽ giúp nông dân hiểu rõ hơn về các xu hướng và liên kết chúng với việc thu hoạch cây trồng và tăng năng suất của nó. Tất cả các điểm dữ liệu liên quan đến một tình trạng như sức khỏe của cây trồng sẽ mất quá nhiều thời gian để phân loại. Chiến lược học không giám sát cũng sẽ giúp đánh giá kết quả nhanh hơn so với phương pháp học có giám sát.

3. Học tăng cường (Reinforcement Learning)

Học tăng cường là một mô hình học tập hành vi. Phản hồi từ phân tích dữ liệu được nhận để hướng dẫn người dùng đạt được kết quả tốt nhất. Học tăng cường (Increased learning - *Lưu ý: từ đúng là "Reinforcement learning"*) khác với các phương pháp khác vì hệ thống không sử dụng một bộ dữ liệu mẫu để huấn luyện. Thay vào đó, hệ thống học bằng cách thử nghiệm và sai sót (testing and error). Do đó, một loạt các lựa chọn thành công sẽ "củng cố" (reinforce) quy trình vì vấn đề được giải quyết tốt nhất.

Hình ảnh hệ thống Tác nhân - Figure Agent system.

Trong Hình, phản ánh kịch bản chung của việc học tăng cường. So sánh, tác nhân (agent) không nhận được dữ liệu được chỉ định (designated) ở đây, không giống như kịch bản học có giám sát được xem xét trong phần trước. Thay vào đó, nó thu thập thông tin bằng cách giao tiếp với thế giới, thông qua một loạt các hành động. Tác nhân nhận được hai loại thông tin để phản hồi một sự kiện: (1) trạng thái của nó (state of play) trong thế giới và (2) các kịch bản thực tế (real-life scenarios), điều này là duy nhất cho nhiệm vụ và mục đích tương ứng của nó. Mục tiêu là để Tác nhân tối đa hóa phần thưởng (reward) của mình và, để đạt được mục tiêu đó, đồng ý về hướng hành động hoặc chính sách (policy) tốt nhất. Tuy nhiên, dữ liệu mà nó thu thập từ hệ thống chỉ là phần thưởng ngay lập tức cho hành động mà nó đã thực hiện. Không có phản hồi nào từ hệ thống về các ưu đãi

(incentives) trong tương lai hoặc dài hạn. Một yếu tố quan trọng của việc (học) tăng cường là tính đến các khoản thưởng hoặc phạt bị trì hoãn (late bonuses or penalties).

Tác nhân phải đối mặt với tình thế tiến thoái lưỡng nan giữa việc khám phá (exploring) các trạng thái và hành động không xác định để thu thập thêm thông tin về Hệ thống và các phần thưởng, và việc sử dụng (using - *Lưu ý: từ đúng là “exploiting” - khai thác*) thông tin đã tích lũy được để tối đa hóa sự đền bù (reparation - *Lưu ý: từ đúng là “reward” - phần thưởng*) của mình. Đây được gọi là sự đánh đổi giữa thăm dò và phát triển (exploitation - *Lưu ý: tài liệu gốc ghi “development”*) vốn có trong học Tăng cường.

Hiểu rằng có nhiều biến thể (variations) giữa kịch bản học tăng cường và học có giám sát trong một số chương trước. So sánh với học có giám sát, không có sự phân phối cố định của các thực thể trong học tăng cường, vốn xác định sự phân phối qua các quan sát. Đó là sự lựa chọn của chính sách. Trên thực tế, những thay đổi nhỏ về chính sách có thể ảnh hưởng mạnh mẽ đến phần thưởng. Ngoài ra, Hệ thống không thể được thiết lập nói chung và có thể khác nhau do hành vi được chọn bởi tác nhân. Điều này có thể thực tế hơn so với học có giám sát thông thường đối với một số vấn đề học tập. Có hai cài đặt chính: một trong đó mô hình môi trường (ambient model) được tác nhân biết đến, điều này làm giảm mục tiêu tối ưu hóa số tiền xuống thành một vấn đề lập kế hoạch (planning problem); và một trong đó mô hình môi trường không xác định và nơi tác nhân phải đối mặt với một câu hỏi học tập. Trong trường hợp trên, tác nhân phải học hỏi từ dữ liệu trạng thái và phần thưởng (recompense) thu được để có được thông tin liên quan và quyết định chiến lược tốt nhất.

Học tăng cường không phải là Học có giám sát một cách cụ thể vì không hoàn toàn dựa vào việc thu thập dữ liệu “có giám sát” (hoặc được gán nhãn) (bộ sưu tập huấn luyện). Trên thực tế, phản hồi của các hành động được thực hiện có thể được kiểm soát và tính toán dựa trên một khái niệm về “phần thưởng”. Tuy nhiên, nó cũng không phải là học không giám sát vì chúng ta biết trước phần thưởng mong muốn khi chúng ta hình thành “người học” của mình.

III. Học có giám sát Vs. Không giám sát Vs. Tăng cường

Cuối cùng, vì tất cả đều đã nhận thức rõ về học có giám sát, không giám sát và Tăng cường, hãy nhìn vào khoảng cách giữa các loại hình học này. Tóm lại, học có giám sát xảy ra khi một mô hình học có hướng dẫn từ một bộ dữ liệu được xác định (defined). Và học không giám sát là nơi máy tính được huấn luyện mà không có bất kỳ hướng dẫn nào trên cơ sở dữ liệu không được gán nhãn. Học tăng cường xảy ra khi một máy tính hoặc một tác nhân giao tiếp, thực hiện các hành động và học hỏi bằng quy trình thử-và-sai (test-and-error).

Bảng sau đây:


Tiêu chí (Criteria)	Học có giám sát (Supervised Learning)	Học không giám sát (Unsupervised learning)	Học tăng cường (Reinforcement Learning)
Định nghĩa	Mô hình học bằng cách sử dụng dữ liệu được gán nhãn hoặc được phân loại.	Mô hình được huấn luyện với dữ liệu không được phân loại hoặc không được gán nhãn.	Một tác nhân tương tác với mô hình bằng cách thực hiện hành động & học hỏi từ các lỗi và phần thưởng.
Loại vấn đề	Hồi quy & Phân loại.	Kết hợp & Phân cụm.	Dựa trên phần thưởng.
Loại dữ liệu	Dữ liệu được gán nhãn.	Dữ liệu không được gán nhãn.	Không có dữ liệu được xác định trước.
Huấn luyện	Giám sát bên ngoài.	Không có sự giám sát.	Không có sự giám sát.
Phương pháp tiếp cận	Ánh xạ các đầu vào được gán nhãn hoặc được phân loại tới các đầu ra đã biết.	Nhận dạng mẫu trong dữ liệu không được phân loại và khám phá ra đầu ra.	Nó tuân theo phương pháp thử và sai (trial and error).

IV. Các thuật toán học máy phổ biến nhất

- **Hồi quy tuyến tính (Linear Regression):** Đây là một trong những thuật toán thống kê và học máy phổ biến nhất. Hồi quy tuyến tính về cơ bản là một mô hình tuyến tính (linearity) giả định mối quan hệ tuyến tính giữa các biến đầu vào x và y . Nói cách khác, bạn có thể tính toán các biến đầu vào x từ một tổ hợp tuyến tính. Nó có thể được định nghĩa bằng một đường thẳng phù hợp nhất (best line) để tạo mối quan hệ giữa các biến. Hồi quy tuyến tính thường có hai loại:
 - **Hồi quy tuyến tính đơn giản (Simple Linear Regression):** Một thuật toán hồi quy tuyến tính được coi là hồi quy tuyến tính đơn giản vì chỉ có một biến độc lập.
 - **Hồi quy tuyến tính bội (Multiple Linear Regression):** Nếu có nhiều hơn một biến độc lập, một thuật toán hồi quy tuyến tính được coi là hồi quy tuyến tính bội. Hồi quy tuyến tính chủ yếu được sử dụng để ước tính các giá trị thực dựa trên (các) biến liên tục. Ví dụ, doanh số bán hàng cả ngày của một cửa hàng có thể được tính toán bằng hồi quy tuyến tính dựa trên các giá trị thực.
- **Hồi quy Logistic (Logistic Regression):** Nó còn được gọi là hồi quy logit (logit regression). Đây là một thuật toán phân loại. Hồi quy Logistic chủ yếu là một


thuật toán phân loại được sử dụng để ước tính các giá trị rời rạc như 0 hoặc 1, đúng hoặc sai hoặc có hoặc không dựa trên một tập hợp riêng biệt các biến. Về lý thuyết, nó dự đoán rằng đầu ra của nó sẽ nằm trong khoảng từ 0 đến 1.

- **Cây quyết định (Decision Tree):** Đây là một thuật toán học có giám sát chủ yếu được sử dụng để phân loại vấn đề. Về cơ bản, đây là một phân vùng được phân loại (graded partition) dựa trên các biến độc lập như một phân đệ quy (recursive partitive). Cây quyết định có các nút cây có gốc (rooted tree nodes). Cây có gốc là một cây có hướng với một nút gốc. Gốc không có cạnh vào và tất cả các nút khác đều có một cạnh vào. Những nút (cuối cùng) như vậy được gọi là lá hoặc nút phán đoán (judgment).



Hình 3.2: Cây quyết định

- **Máy Vector hỗ trợ (Support Vector Machine - SVM):** Nó được sử dụng cho các bài toán phân loại và hồi quy. Tuy nhiên, nó chủ yếu được sử dụng cho các bài toán phân loại. Nguyên tắc chính của SVM là gán mỗi yếu tố dữ liệu trong không gian n -chiều làm giá trị của đặc trưng riêng lẻ. Ở đây n là các đặc trưng (features) chúng ta có. Sau đó, một biểu diễn đồ họa đơn giản để nắm bắt định nghĩa SVM từ Hình 3.3 SVM.



Hình 3.3: SVM

- Các Vector hỗ trợ (Support Vectors) Trong Hình 3.3 SVM ở trên, chúng ta có hai đặc trưng, do đó, trước tiên chúng ta cần ánh xạ hai biến như vậy trong không gian hai chiều, nơi mỗi điểm có hai tọa độ, được gọi là các vector hỗ trợ. Đường thẳng chia dữ liệu thành hai loại được phân loại riêng biệt. Đường thẳng này là bộ phân loại (classifier) trong SVM.
- **Naïve Bayes:** Đây cũng là một kỹ thuật phân loại. Định lý Bayes là một nguyên tắc để xây dựng các bộ phân loại đằng sau kỹ thuật phân loại này. Các yếu tố dự đoán (predictors) được cho là độc lập. Nói một cách đơn giản, sự bao gồm (inclusion) của một đặc trưng cụ thể trong một lớp không liên quan đến đặc trưng của bất kỳ đặc trưng nào khác. Sau đây là phương trình của định lý Bayes:

$$P(A | B) = P(B | A)P(A)/P(B)$$

Mô hình Naïve Bayes rất đơn giản để phát triển và đặc biệt hữu ích cho các tập dữ liệu lớn.

- **K-Nearest Neighbors (KNN) (K-Láng giềng gần nhất):** Nó được sử dụng để xác định các vấn đề và khắc phục chúng (identify problems and to rectify them - *Lưu ý: cách diễn đạt này không chuẩn, KNN dùng cho phân loại/hồi quy*). Nó thường được sử dụng để giải quyết các vấn đề với phân loại. Nguyên tắc chính của thuật toán này là nó lưu trữ tất cả các trường hợp (cases) hiện có và bằng cách bỏ phiếu đa số (plurality voting) của các láng giềng của nó để phân loại các trường hợp mới. Trường hợp này sau đó được gán cho lớp mà, theo một hàm khoảng cách, là phổ biến nhất trong số K láng giềng gần nhất của nó. Khoảng cách (The gap) có thể là Minkowski, Euclidean, và Hamming. Xem xét KNN như sau:
 - Về mặt tính toán, KNN đắt đỏ hơn các thuật toán khác được sử dụng cho các bài toán phân loại.
 - Việc chuẩn hóa các biến là cần thiết, nếu không các biến có phạm vi (range) cao hơn có thể làm sai lệch nó.
 - Tại KNN, chúng ta sẽ làm việc trên một giai đoạn như giảm nhiễu (noise reduction), tiền xử lý (pre-processing).
- **K-Means Clustering (Phân cụm K-Means):** Điều này được sử dụng để giải quyết vấn đề của các cụm (clusters), như tên gọi của nó. Đây là một loại Học không giám sát. Nguyên tắc chính của thuật toán K-Means là gán (phân chia) tập dữ liệu qua các cụm khác nhau. Hãy làm theo các bước sau để xây dựng các cụm K-means:
 - K-means chọn k số điểm cho mỗi cụm được gọi là tâm cụm (centroids).
 - Mỗi điểm dữ liệu bây giờ tạo thành một cụm, tức là k cụm, với các tâm cụm gần nhất.
 - Bây giờ, các tâm, dựa trên các thành viên hiện tại của mỗi cụm, sẽ được xác định (tính toán lại).
 - Các biện pháp (bước) này cần phải được lặp lại cho đến khi sự hội tụ (convergence) diễn ra.

- **Rừng ngẫu nhiên (Random Forest):** Đây là một thuật toán phân loại có giám sát. Thuật toán rừng ngẫu nhiên có ưu điểm là nó có thể được sử dụng cho các bài toán phân loại cũng như hồi quy. Về cơ bản, đây là tập hợp các cây ra quyết định (khu rừng) hoặc tập hợp (ensemble) các cây ra quyết định. Nguyên tắc cơ bản của rừng ngẫu nhiên là mỗi cây được phân loại (graded) và khu rừng chọn ra các phân loại (grades) tốt nhất. Những ưu điểm của thuật toán Random Forest như sau:
 - Bộ phân loại rừng ngẫu nhiên có thể được sử dụng cho các chức năng phân loại và hồi quy.
 - Các giá trị bị thiếu (missing values) có thể được quản lý.
 - Ngay cả khi chúng ta có nhiều cây hơn trong rừng, điều này sẽ không làm mô hình bị quá khớp (over suit the pattern).

V. Ứng dụng (Applications)

- **Các nhà bán lẻ** Học máy trong nông nghiệp được các nhà bán lẻ hạt giống sử dụng để biến dữ liệu thành sản lượng cây trồng tốt hơn. Thông qua việc các công ty kiểm soát dịch hại sử dụng chúng, vi khuẩn, bọ và sâu bọ (vermin) đang phát triển có thể được phát hiện.
- **Robot nông nghiệp (Agriculture Bots)** Phần lớn các công ty hiện đang chuẩn bị và chế tạo robot cho sứ mệnh nông nghiệp chính. Điều này bao gồm việc xử lý hạt giống và làm việc hiệu quả hơn nhân lực. Đây là ví dụ mới nhất về học máy trong nông nghiệp.
- **Lai tạo giống (Species Breeding)** Chọn lọc giống là một phương pháp tìm kiếm lặp đi lặp lại các gen cụ thể, quyết định hiệu quả sử dụng nước và chất dinh dưỡng, khả năng chịu đựng khí hậu, kháng bệnh, hàm lượng dinh dưỡng hoặc hương vị. Trong việc phân tích sản xuất cây trồng ở các vùng khí hậu khác nhau và phát triển các công nghệ mới, học máy, đặc biệt là các thuật toán học sâu (profound learning), đòi hỏi hàng thập kỷ dữ liệu thực địa. Dựa trên dữ liệu này, một mô hình thống kê có thể được phát triển để dự đoán gen nào có khả năng đóng góp nhất vào lợi ích (gain) của cây trồng.
- **Nhận dạng loài (Species Recognition)** Phương pháp tiếp cận thông thường của con người để phân loại thực vật là so sánh màu sắc và hình dạng của lá, nhưng bằng cách sử dụng phân tích thống kê của Học máy (Machine Learning's) có thể cung cấp kết quả nhanh hơn và chi tiết hơn bằng cách phân tích hình thái (morphology) của lá và cung cấp thêm chi tiết về các đặc tính của lá.
- **Sản lượng (Yield Production)** Dự báo năng suất là một trong những chủ đề của nông nghiệp chính xác cao (steep-precision agriculture), vì nó xác định việc lập bản đồ và dự đoán năng suất, khớp nối nhu cầu cây trồng và quản lý cây trồng. Các kỹ thuật hiện đại (state-of the-art) đã vượt xa dự đoán đơn giản dựa trên dữ liệu lịch sử, mà đã bao gồm các kỹ thuật học máy để cung cấp kiến thức liên quan

đến cây trồng, thời tiết và hoàn cảnh kinh tế và phân tích đa chiều sâu rộng để tối ưu hóa lợi nhuận cho nông dân và cộng đồng.

- **Phát hiện bệnh (Disease Detection)** Học máy có thể được sử dụng để phát hiện các bệnh lây nhiễm ở Thực vật, thường gây ra bởi dịch hạch (plague), côn trùng, bệnh tật và, trừ khi được quản lý kịp thời, chúng làm giảm năng suất trên quy mô lớn. Liên quan đến diện tích trồng trọt tính bằng mẫu Anh (acres), người trồng trọt rất tẻ nhạt (tedious) để theo dõi cây trồng hàng ngày. Bằng cách triển khai Học máy ở đây, nó cung cấp giải pháp để theo dõi khu vực canh tác một cách nhất quán và cung cấp khả năng phát hiện bệnh tự động bằng hình ảnh viễn thám.
- **Chất lượng cây trồng (Crop Quality)** Sản lượng dữ liệu (Data output) có thể được đo lường và xác định đầy đủ để nâng giá sản phẩm và giảm lãng phí. Trái ngược với các chuyên gia con người, máy móc có thể sử dụng dữ liệu và các giao diện (interfaces) dường như không liên quan để khám phá và xác định các phẩm chất mới đóng vai trò trong chất lượng tổng thể của cây trồng.
- **Phát hiện cỏ dại (Weed Detection)** Cỏ dại là mối đe dọa lớn đối với sản xuất cây trồng, ngoài các loại bệnh. Vấn đề chính trong cuộc chiến chống lại cỏ dại là chúng khó phân biệt và nhận diện (discriminate) với cây trồng. Các thuật toán thị giác máy tính (Computer vision) và ML có thể tăng cường khả năng nhận diện và phân biệt cỏ dại với chi phí thấp mà không có các vấn đề môi trường hoặc tác dụng phụ. Các công nghệ này sẽ thúc đẩy robot tiêu diệt cỏ dại và giảm nhu cầu sử dụng thuốc diệt cỏ trong tương lai.
- **Quản lý đất (Soil Management)** Đất là một nguồn tài nguyên thiên nhiên rất đa dạng với các quy trình phức tạp và các cơ chế không rõ ràng đối với các chuyên gia nông nghiệp. Nhiệt độ của chính nó có thể cung cấp cái nhìn sâu sắc về tác động của biến đổi khí hậu đối với lợi nhuận lãnh thổ (territorial returns). Các thuật toán học máy nghiên cứu quá trình bốc hơi, độ ẩm của đất và nhiệt độ để hiểu động lực của hệ sinh thái và các tác động của nông nghiệp.
- **Quản lý nước (Water Management)** Sự cân bằng thủy văn (hydrological), khí hậu (climatological) và nông nghiệp của các nguồn tài nguyên nước trong nông nghiệp có một ý nghĩa. Sử dụng các hệ thống tưới tiêu hiệu quả hơn và dự báo nhiệt độ điểm sương (dewpoint) hàng ngày, các ứng dụng ML tiên tiến nhất cho đến nay được kết nối với ước tính khí khổng (stomata) hàng ngày, hàng tuần hoặc hàng tháng, giúp phân loại thời tiết dự đoán và ước tính sự bốc hơi.
- **Chăn nuôi (Livestock Production)** Học máy cung cấp dự đoán và tính toán chính xác các thông số canh tác, phù hợp với quản lý cây trồng, để tối đa hóa hiệu quả kinh tế của các hệ thống canh tác như chăn nuôi. Để cho phép nông dân thay đổi chế độ ăn và điều kiện, ví dụ, hệ thống dự báo cân nặng sẽ ước tính trọng lượng tương lai 150 ngày trước ngày họ giết mổ.

Tóm tắt

Học máy đã được sử dụng rộng rãi trong một số lĩnh vực và nó đã trở thành một nhánh quan trọng nhất của Trí tuệ Nhân tạo. Như chúng ta đã thấy, có thể có rất nhiều ứng dụng

của Học máy trong lĩnh vực nông nghiệp, điều này có thể giúp nông dân tăng năng suất cây trồng và cứu chúng khỏi sâu bệnh và các loại côn trùng khác khi thu hoạch trên đồng. Vì vậy, chúng ta có thể thấy học máy có thể hữu ích như thế nào trong lĩnh vực nông nghiệp.