

CÁC THUẬT TOÁN HỌC MÁY

Nền tảng Toán học, Phân tích
Logic và Triển khai với Python


Học phần: Giới thiệu Trí tuệ Nhân tạo | Chương 9




Cơ chế hoạt động của Học Có Giám Sát

Dự đoán một nhãn chưa biết dựa trên các đầu vào đã biết nhãn.

Data + Algorithm = Model




Hồi quy Tuyến tính (Linear Regression)



$$f(x) = mx + b$$


- **Mục tiêu:** Tìm đường thẳng phù hợp nhất (Best-fit line) đi qua dữ liệu phân tán.
- **Hàm chi phí (MSE):** Đo lường khoảng cách lỗi bình phương trung bình.
- **Tối ưu hóa: Gradient Descent** - Lặp lại các bước đi ngược hướng đạo hàm để giảm thiểu lỗi.



Hồi quy Logistic: Bước ngoặt Phân loại


- **Đường cong chữ S (Sigmoid):** Ánh xạ mọi giá trị về khoảng xác suất $[0, 1]$.
- **Phân loại:** Nhị phân (0 hoặc 1) & Đa lớp (One-vs-Rest).
- **Đánh giá:** Dùng Ước lượng Hợp lý Tối đa (MLE) thay vì MSE.

Vấn đề



Bị ảnh hưởng bởi điểm ngoại lệ (Outliers), xác suất có thể < 0 hoặc > 1 .




Giải pháp



Ép xác suất vào khoảng $0 < p < 1$.



Điểm chuẩn: Khám phá Bộ Dữ liệu Iris

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5			Versicolor
...					
150	5.9	3.0			Virginica



- **Đặc trưng (Features - X):** Chiều dài & rộng của Cánh hoa / Đài hoa.
- **Mục tiêu (Target - Y):** 3 giống hoa (Setosa, Versicolor, Virginica).
- **Quy trình chuẩn:** Chia tập Train/Test -> Huấn luyện (Fit) -> Dự đoán (Predict).

Cây Quyết Định (Decision Tree)



- **Phân chia (Splitting):** Đặt các câu hỏi điều kiện tại mỗi nút.
- **Lợi ích thông tin (Information Gain):** Tính toán độ giảm sự hỗn loạn (Entropy).
- **Chỉ số Gini:** Thước đo sự phân loại sai. Gini càng thấp, nhánh càng tinh khiết.

Random Forest: Sức mạnh của Biểu quyết Đa đông





- **Mô hình Ensemble:** Khởi tạo ngẫu nhiên một khu rừng gồm nhiều Cây quyết định.
- **Cơ chế hoạt động:** Mỗi cây tự chấm điểm độc lập -> Lấy kết quả bỏ phiếu đa số (Plurality voting).
- **Ưu điểm vượt trội:** Linh hoạt (Cả Hồi quy & Phân loại), chống nhiễu tốt và khắc phục triệt để lỗi Quá khớp (Overfitting) của cây đơn lẻ.

Sepal length	Sepal width	Petal length	Petal width	Class label
5.1	3.5	1.4	0.2	Setosa
6.4	3.2	4.5	1.5	Versicolor
6.9	3.1	5.1	2.3	Virginica



Máy Vector Hỗ trợ (SVM): Kẻ Vạch Đường Biên

- **Siêu phẳng (Hyperplane):** Mặt phẳng chia cắt không gian dữ liệu thành các phân vùng.
- **Lề (Margin):** Khoảng cách từ Siêu phẳng đến các **Support Vectors** (điểm gần nhất). Lề càng lớn -> Tổng quát hóa càng tốt.
- **Mục tiêu:** Phân tách rõ ràng nhất 2 nhóm dữ liệu trong không gian nhiều chiều.



K-Nearest Neighbors (KNN): Bạn là ai, hãy nhìn hàng xóm!

- Phân loại dữ liệu mới bằng bỏ phiếu đa số từ K láng giềng gần nhất.
- Yêu cầu chuẩn hóa dữ liệu & tốn nhiều bộ nhớ (phải tính khoảng cách tới mọi điểm).



Naïve Bayes: Phân loại bằng Xác suất Tiên nghiệm





$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)}$$

- **Dựa trên Định lý Bayes:** Xác suất hậu nghiệm = (Xác suất có điều kiện × Tiên nghiệm) / Xác suất Dữ liệu.
- **Sự “Ngây thơ” (Naïve):** Giả định tuyệt đối rằng tất cả các đặc trưng (Features) hoàn toàn độc lập với nhau (hiếm gặp trong thực tế).
- **3 Biến thể Python:** Gaussian (Phân phối chuẩn), Multinomial (Đếm rời rạc), Bernoulli (Nhị phân).


	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
count	150.0	150.0	150.0	150.0
mean	5.8433	3.0573	3.7580	1.1993
std	0.8281	0.4359	1.7653	0.7622
min	4.3000	2.0000	1.0000	0.1000
25%	5.1000	2.8000	1.6000	0.3000
50%	5.8000	3.0000	4.3500	1.3000
75%	6.4000	3.3000	5.1000	1.8000
max	7.9000	4.4000	6.9000	2.5000

K-Means Clustering: Gom cụm Không Giám Sát


- **Mục tiêu:** Khám phá cấu trúc ngầm của dữ liệu không có nhãn.
- **Thuật toán lặp 2 bước:** (1) Gán cụm điểm dữ liệu vào Tâm (Centroid) gần nhất -> (2) Dời Tâm về trung bình của cụm mới. Lặp đến khi hội tụ.




Actual Data Distribution



Predicted Boundaries (K-Means)



Đánh Giá Hiệu Suất: Làm sao biết máy đã học đúng?



Báo cáo Phân loại (Classification Report)

Class	Precision	Recall	F1-Score	Support
Class A	0.86	0.91	0.88	115
Class B	0.89	0.83	0.86	135
Class C	0.81	0.83	0.86	250
Macro avg	0.87	0.87	0.87	250
/ Total	0.87	0.87	0.87	250



- Độ chính xác (Accuracy): Tỷ lệ dự đoán đúng trên tổng số mẫu.




- Cảnh báo Overfitting (Quá khớp): Đạt 100% trên tập Huấn luyện (Train) có thể là thảm họa trên tập Kiểm tra (Test) do mô hình chỉ học vẹt dữ liệu cũ.



Ma Trận So Sánh: Hồi quy, Khoảng cách & Xác suất

Thuật Toán	Ưu điểm	Khuyết điểm
Linear/Logistic Regression 	Đơn giản, tính toán cực nhanh, có điểm xác suất.	Yếu đuối trước dữ liệu phi tuyến tính phức tạp và Outlier.
SVM 	Phân vùng mạnh mẽ với "Lề" rõ ràng.	Chật vật nếu không gian dữ liệu bị chồng chéo nhiều.
KNN 	Dễ hiểu, không áp đặt giả định lên dữ liệu.	Tốn RAM, tính toán cực kỳ chậm khi Big Data.
Naïve Bayes 	Huấn luyện xuất sắc với Data nhỏ.	Giả định các đặc trưng "độc lập" xa rời thực tế.

Ma Trận So Sánh: Cây Quyết Định & Học Không Giám Sát

Thuật Toán	Ưu điểm	Khuyết điểm
Decision Tree 	Mô phỏng logic con người, mô hình minh bạch dễ giải thích.	Cực kỳ dễ rơi vào bẫy Quá khớp (Overfit) nếu cây mọc quá sâu.
Random Forest 	Siêu mạnh mẽ, miễn nhiễm tốt với Overfit, xử lý Dữ liệu khuyết.	Là một "Hộp đen" (Black box), tốn RAM và dự đoán chậm.
K-Means (Unsupervised) 	Hiệu quả tính toán vượt trội cho bài toán gom cụm.	Phải tự đoán số cụm (K) từ đầu, nhạy cảm với hình dạng dữ liệu.
		

Lời Giải Nằm Ở Dữ Liệu Của Bạn



- Không có thuật toán vô địch, chỉ có thuật toán Phù hợp nhất.
- Quyết định dựa trên: (1) Kích thước bộ dữ liệu, (2) Đặc thù bài toán (Nhấn có sẵn hay Không), và (3) Tài nguyên phần cứng (Memory vs. Speed).
- Sẵn sàng để Triển khai. Đã đến lúc đưa các Mô hình từ Python ra thế giới thực!